

Remerciements

Je souhaite exprimer ma gratitude à toutes les personnes qui m'ont accompagné et soutenu tout au long de ce projet de fin d'étude.

En premier lieu, je remercie chaleureusement **Hervé OLRÉY**, mon tuteur de stage, pour son suivi régulier et ses orientations tout au long du stage. Ses services et ses interventions m'ont grandement facilité l'accès aux machines, d'autres équipements et fournisseurs, me permettant ainsi de mener mes tests dans les meilleures conditions.

Mes remerciements vont également au **Pr. Dominique KNITTEL**, mon tuteur faculté, pour son suivi régulier et ses orientations tout au long du stage. Ses échanges et retours ont enrichi mes réflexions et ma capacité à prendre du recul sur les défis rencontrés.

Je tiens à exprimer ma sincère gratitude envers les régleurs et les monteurs, en particulier **Georges MATHE** et **Recep RUZGAR**, avec qui j'ai collaboré et échangé. Leur contribution a été un facteur clé dans la réussite de mon projet.

Je remercie notamment **l'équipe de mon bureau d'étude** pour leur soutien constant et leur expertise durant le déroulement du stage. Leurs interventions m'ont permis de surpasser des obstacles durant le déroulement du stage.

Enfin, j'exprime ma gratitude envers les personnes qui ont contribué de loin ou de près au projet : **Fernanda TOSQUI** : pour sa bonne humeur et sa positivité, **Cédric RITONDO** : pour ses conseils avisés en matière de traitement de signal et **Dominique MOREL**.

Abréviations

IA	Intelligence Artificielle
CNN	Convolutional Neural Network
RNN	Recurrent Neural Network
AE	AutoEncoder / AutoEncodeur (FR)
CAE	Convolutional AutoEncoder
VAE	Variational AutoEncoder
KNN	K-nearest Neighbor
SVM	Support Vector Machine
LSTM	Long Short Term Memory
DL	Deep Learning
RL	Reinforcement Learning
ML	Machine Learning
FFT	Fast Fourier Transform
IF	Imprimeuse Flexographique
AppE	Appel d'entrée
AppS	Appel de sortie
Main	Axe de maintien
Arra	Axe d'arrache
SIMO	Simotion Scout
OPC UA	Open Platform Communication Unified Architecture
IHM	Interface Homme-Machine
API	Application Programming Interface

Table des matières

Remerciements	2
Abréviations	3
Table des matières	4
Chapitre I Introduction.....	7
1 Organisme d'accueil.....	7
2 Situation de départ.....	8
3 Outils à disposition.....	9
Chapitre II Gestion du projet.....	10
Chapitre III Problématique.....	13
1 Mise en scène.....	13
2 Présentation générale d'une ligne de production.....	13
3 Processus de fabrication d'un sac.....	15
4 Critère de réglage.....	17
5 Analyse des signaux : capteur présent et ajouté.....	18
5.1 Données Simotion.....	18
5.2 Signaux vibratoires.....	21
5.3 Signaux acoustiques.....	23
6 État de la machine.....	26
7 Les défauts.....	26
8 Définition de la problématique.....	28
Chapitre IV État de l'art.....	29
1 Introduction.....	29
2 Les approches actuelles d'IA.....	30
3 Utilisation d'autoencodeur.....	31
4 Exploitation de l'espace latent.....	33
5 Généralisation de l'IA dans le cadre industriel.....	34
Chapitre V Phase exploratoire de recherche.....	36
1 Preprocessing.....	36
2 Approches pour Simotion.....	37
2.1 Autoencodeur : reconstruction multi branche.....	37

	2.1.1	Méthode.....	38
	2.1.2	Entraînement.....	41
	2.1.3	Résultats.....	41
2.2		Classificateur : fusion des données time-series.....	43
	2.2.1	Méthode.....	43
	2.2.2	Entraînement.....	44
	2.2.3	Résultats.....	45
3		Approches pour signaux vibratoires.....	46
3.1		Autoencodeur : images scalogrammes.....	46
	3.1.1	Méthode.....	47
	3.1.2	Optimisations.....	48
	3.1.3	Résultats.....	48
3.2		Feature extraction : images log spectres.....	49
	3.2.1	Méthode.....	50
	3.2.2	Optimisations.....	51
	3.2.2	Résultats.....	54
4		Approches pour signaux acoustiques.....	56
4.1		Transfer learning : fusion de 3 approches.....	56
	4.1.1	Méthode.....	56
	4.1.2	Résultats.....	58
4.2		Few-shot learning : fine tuning supervisé.....	59
	4.2.1	Méthode.....	59
	4.2.2	Résultats.....	60
5		Synthèse des modèles d'IA.....	64
Chapitre VI		Phase d'implémentation.....	66
1		Pipeline globale.....	66
1.1		Architecture d'acquisition et intégration.....	67
	1.1.1	Modification du programme.....	67
	1.1.2	Tâche ServoSynchronousTask.....	67
	1.1.3	Interface ergonomique.....	68
	1.1.4	Mise en place de l'OPC UA.....	68
1.2		Edge Gateway.....	69
1.3		Déploiement IA.....	70

1.3.1	Création du conteneur Docker.....	70
1.3.2	Communication API.....	72
1.3.3	Implantation dans le boîtier Belden.....	72
2	Résultats.....	73
3	Remarques.....	74
Chapitre VII	Résumé global.....	75
1	Partie recherche.....	75
2	Partie implémentation.....	75
Chapitre VIII	Conclusion et perspectives.....	76
1	Conclusion générale.....	76
2	Perspectives et travaux restants.....	77
Bilan financier		78
Bibliographie		79
Annexe		81
Résumé		99

Chapitre I : Introduction

1 Organisme d'accueil

Holweg fait partie d'un groupe REPAKT comportant plusieurs entreprises du même secteur mais dans des localisations différentes : Holweg - France, Weber - USA et MDM - Chine.

Situé à Molsheim et étant un pionnier de la fabrication de machine à sac depuis 1889, Holweg compte aujourd'hui un effectif sur site approchant les 100 employés.

Même si le groupe REPAKT se focalise sur la conception et fabrication de machine à sac, les différentes entreprises, Holweg, Weber et MDM, agissent sur des secteurs légèrement différents.

Cependant, Holweg est particulier car c'est le seul site produisant des machines fonctionnelles pour le E-commerce. Ainsi, Holweg se démarque des compétiteurs grâce à leur polyvalence dans le milieu de la fabrication de sac à divers formats (pour l'agroalimentaire, le fast-food, l'E-commerce ou le shopping).

Holweg a pour vocation de faire évoluer le marché industriel vers un marché plus sain écologique. Avec les normes tel ISO 9001, les machines sont donc suivies de près par les équipes service après vente pour satisfaire au mieux les clients et les réparer à distance si besoin.

Avec leur ambition vers l'industrie du futur, l'entreprise ne cesse de développer et d'améliorer ses machines pour inclure, de plus en plus, les innovations de demain.

Ainsi, en s'appuyant sur plus de 135 ans d'expertise, Holweg se positionne comme un leader du smart packaging, alliant polyvalence produit, qualité certifiée et innovations durables pour accompagner ses clients vers une production de sacs éco-responsables et connectés.

2 Situation de départ

Dans le cadre du master Mécatronique, Énergie et Systèmes Intelligents (MESI), un projet de fin d'étude est à réaliser en entreprise pour valider à la fois la fin du master mais aussi nos compétences scientifiques en environnement réel. L'objectif primaire de ce projet est de mettre en place une solution viable dans les machines afin d'assister les régulateurs et réduire la casse-papier durant la formation du boyau. Ce projet de grande envergure s'inscrit directement dans la transition industrielle vers la 4.0 et 5.0 où le but est de pouvoir faciliter, aider et assister les opérateurs au bon fonctionnement de la machine.

Par ailleurs, ce projet projette des idées en lien avec des travaux menés par le Pr. Knittel qui étudie depuis plusieurs années l'application de l'IA dans les environnements industriels comme la détection d'anomalie et l'optimisation de machines. Nous avons donc bénéficié d'aides matérielles ainsi que d'expériences qui nous ont permis d'avancer rapidement.

Comme Holweg a pour ambition d'évoluer de plus en plus vers cette révolution industrielle, l'entreprise a donc entrepris des efforts pour mettre en place des infrastructures pour la supervision à distance. Aujourd'hui, Holweg tient à maintenir sa position de leader dans son domaine. C'est dans cette perspective que s'inscrit la pertinence de notre projet.

Le bureau d'étude automatisme nous a donc accueilli pour continuer ce projet, attendant plusieurs livrables :

- **À court terme** : Rapport d'analyse sur l'algorithme existant, cahier des charges des améliorations.
- **À moyen terme** : Prototype fonctionnel testé en conditions réelles avec une interface utilisateur adaptée.
- **À long terme** : Solution validée sur machine pilote et plan de déploiement global accompagné d'un guide d'utilisation.

En finalité, les conséquences attendues seraient :

La réduction des casses-papier et des pertes liées aux réglages incorrects.

La simplification du travail des régulateurs, notamment pour les nouveaux collaborateurs.

Le déroulement du projet s'est ainsi articulé autour de 4 étapes :

1. **Identifier** et **collecter** les données nécessaires
2. **Entraîner** des modèles capables de répondre aux problématiques respectives et ainsi émettre une **preuve de concept**
3. **Mettre en oeuvre** l'approche en utilisant les infrastructures industriels
4. **Valider** la solution par des tests approfondis et préparer un plan de déploiement global

3 Outils à disposition

Pour mener à bien notre projet, nous disposons déjà d'un ensemble d'outils, auxquels se sont ajoutées plusieurs installations spécifiques :

- Protocole de communication : MQTT, IO-Link, UA Expert
- Environnements de développement et déploiement : VSCode, Docker
- Logiciel éditeurs et configurateur fournisseur :
 - PACTware (Pepperl & Fuchs)
 - IODD DTM config
 - TIA Portal
 - Simotion Scout

Heureusement, la plupart des outils industriels offrent aujourd'hui une interface web locale :

- Configuration web du serveur Simotion pour implémenter l'OPC UA
- Interface et configuration web du boîtier Belden Hirschmann OpEdge 8D

Cette accessibilité simple et facile a grandement simplifié la maintenance, le temps d'implémentation ainsi que de débogage suite au développement du projet.

Chapitre II : Gestion du projet


Pour maximiser les chances de succès de notre projet, une gestion du temps et des ressources est cruciale. Nous avons ainsi mis en place une fiche de suivi (**figure ci-dessous**) permettant au tuteur de l'entreprise de suivre nos démarches, avancements, résultats et de nous remettre dans le droit chemin si nécessaire. Cet outil nous a permis de contourner des obstacles pour se concentrer sur d'autres parties du projet afin de maximiser le temps disponible.

Semaine ■ Point (n-1)	■ Travail effectué (n)	■ Pour la prochaine fois (n+1) ■
1	-État de l'art -Lecture du rapport + fichiers Théo -Apperçu des machines RS26 -Contextualisation de la problématique / enjeux -Remarques démarches Théo -Approche détaillée du processus de fabrication d'un sac avec George -1er idées venues pour la détection + réglage par IA -Analyse + remarque de la database -Suggestion d'amélioration pour la collecte de données -Mise en marche d'un 1er prototype IA + amélioration	-définir le matériel nécessaire pour la prise de mesures --> Instrumentalisation (capteur : choix, où, comment) -réfléchir pour un pronostic en plus du diagnostic -découvrir l'E-COM1/2 w/ Maxence -commencer à utiliser les logi SIEMENS -Voir avec Jean François BOULLE pour des questions contrôle moteur -observer les travaux des autres de l'équipe Autom plus en détail
2	-Les démarches de Théo ont été lu et comprises -Les différents enjeux / problématiques ont été découvert avec George -RS26 a été exploré en détail avec George -Des suggestion d'amélioration ont été discuté avec George --> Il n'est pas favorable au projet -Des dizaines de prototype sont en cours de développement --> Pour l'instant, aucun ne dépasse 90% de précision -État de l'art est encore en train d'être continué	-Faire une liste matériels à commander -Penser à faire des traces à partir des machines à l'étranger -Penser à rajouter des capteurs si besoin -Raffiner la méthode de diagnostic -Penser à rajouter des capteurs pour avoir une automatisation du processus d'acquisition de données (pour les réglages mécaniques)

Des états d'avancement ont notamment lieu toutes les fins de semaine pour discuter de ce qui a été effectué et les tâches à réaliser pour la semaine suivante. Ces réunions ont servi de guide pour définir les priorités à suivre.

Enfin, nous avons notamment un journal de bord que nous remplissons à chaque idée venues, résultats et problèmes pour garder une trace et recueillir toutes les activités journalières.

2024/2025



Remarques : Compte tenu de la disponibilité extrêmement courte des machines client RS26, nous avons dû déployer, implémenter et tester notre modèle sur la cible embarqué en moins d’une semaine.

En effet, les machines tests n’étaient disponibles qu’à deux moments précis : durant le début du stage et à la fin, comme vous pouvez l’observer sur le diagramme de Gantt (**figures ci-dessus**).

De ce fait, les tests n’ont été achevés qu’à moitié, nous laissant pas le temps de raffiner l’implémentation.

Chapitre III : Problématique

1 Mise en scène

Lors de la formation du boyau, le papier subit des efforts localisés dans des zones spécifiques. Cependant, ces efforts locaux sont difficiles à tracer en raison de leur nature et la dynamique du papier (élasticité variable, papier de caractéristique différente) et des réglages de la machine. En effet, sur chaque machine, le comportement du papier évolue selon les différents jeux de réglage possibles et notamment en fonction de la cadence de la machine. Ainsi, il est quasiment impossible de prédire le comportement du papier par des simulations multi-physiques simples.

Actuellement, les réglages de la machine reposent intégralement sur l'expérience empirique de chaque régleur. Ce processus, fondé sur le toucher et l'ouïe, est chronophage et complexe : atteindre un réglage optimal nécessite une expertise pointue. Or, former un régleur compétent implique un investissement temporel conséquent, d'autant plus que chaque machine et chaque type de papier possèdent leurs propres spécificités, rendant la transmission de ce savoir-faire particulièrement ardue. Les nouveaux opérateurs ne disposent souvent pas du temps requis pour acquérir cette maîtrise.

2 Présentation générale d'une ligne de production

Afin de comprendre les problématiques de notre projet, il est essentiel de comprendre le fonctionnement de notre machine cible : la RS26 (**figure ci-dessous**).



figure 1 : Ligne de production d'une RS26
(source : rapport de Théo Gallet)

Une ligne de production la plus basique comme celle de la RS26 comporte plusieurs enchaînements de machine, allant du dérouleur à l'éjection du sac final dans la fin de ligne. Nous pouvons illustrer le déroulement du papier comme dans le schéma ci-dessous (**Tableau 1**). Une courte liste des différents automates utilisés est notamment en **annexe tableau 1**.

Chap III. 2 Présentation générale d'une ligne de production







Machine	Illustration	Photo	Fonction
dérouleur (DHS)			Dérouler la bobine papier pour former une bande. Présence d'un baladeur pour maintenir une tension stable.
imprimeuse (IF)			Imprimer un motif / couleur sur la bande. Maintient la tension.
Perforateur (RS26)			Perfore légèrement la bande papier pour faciliter la séparation du sac depuis la bande. Il est nécessaire pour former un sac de bon format.
Formation du boyau (RS26)			Plie la bande pour générer la forme globale du sac progressivement. Présence la plus forte de réglage manuel.
Maintien (bleu) Arrache (beige) (RS26)			Arrache le sac du reste de la bande pour former le sac final. Maintien la bande de l'autre côté pour éviter une rupture prématurée.
Fin de ligne (RS26)			Range les sacs proprement pour être manipulés par les opérateurs.

Tableau 1 : Processus de fabrication d'un sac papier avec illustration et photo

3 Processus de fabrication d'un sac




figure 2 : fabrication du sac depuis la RS26 seulement - passage d'une bande au sac
(source : notice RS26)

Comme expliqué précédemment (**tableau 1**), la bande papier passe par plusieurs processus afin d'obtenir un sac en sortie. Néanmoins, certaines transformations sont moins impactantes que d'autres. En effet, parmi la ligne classique de production d'une RS26, les machines comme l'IF et le DHS n'impacte pas autant l'intégrité de la bande qu'au sein même de la RS26. C'est pourquoi cette partie se consacre intégralement aux processus de fabrication d'un sac : c'est-à-dire le moment où la bande déroulée sera formaté pour former le sac final (**figure 2**).

Si nous spécialisons notre étude sur le RS26, nous pouvons observer plusieurs axes motorisés qui nous intéresse (voir en parallèle **figure 3**):

- (1) **appel d'entrée (AppE)** : tirant la bande en amont de la machine
- (2) **axe perforateur (Perfo)** : permettant la perforation de la bande
- (3) **appel de sortie (AppS)** : tirant la bande après le boyau
- (4) **axe de maintien (Main)** : qui maintient la bande pour arracher
- (5) **axe d'arrache (Arra)** : qui arrache la bande lorsqu'elle est maintenu




figure 3 : aperçu 3D des différents axes motorisés sur la RS26 (source : notice RS26)

Contrairement à l'IF et au DHS, qui se contentent de maintenir une tension constante ou de dérouler le papier, les axes motorisés interviennent directement sur la déformation du matériau : ajustement de la tension, vitesse, perforation, pression. Si ces paramètres sont mal réglés, une casse-papier peut se produire au niveau du boyau.

Il est donc particulièrement pertinent d'étudier le rôle du boyau dans la survenue de ces cassures. Bien que le boyau ne soit ni un moteur ni un axe motorisé, il influe fortement sur la cohésion de la bande de papier. Il constitue la zone où les frottements sont les plus importants, car il transforme la bande plane en un sac aux formes complexes (voir **figure 4**).




figure 4 : aperçu du boyau en 3D (b) avec une photo de pliures dans un cas réel (a)
(source photo : RS26 client chez Holweg, source figure : notice RS26)




figure 5 : exemples des nombreux réglages manuels à effectuer
(source : RS26 client Mettler chez Holweg, Molsheim)

Cependant, il ne faut pas se méprendre : les réglages moteurs ne sont pas la seule cause de casse-papier. La plupart des opérations sur la RS26 sont réalisées manuellement et requièrent à la fois l'expérience de l'usage de papier et de la machine pour obtenir un réglage optimal (voir **figure 5**).

Il est important de noter que l'intégralité des réglages n'ont pas été surligné. Il en existe sur plusieurs parties de la machine, nécessitant ainsi une opération simultanée.

4 Critère de réglage

Le réglage de la RS26 se décompose en quatre étapes principales :

1. **Installation de la bobine** sur le DHS.
2. **Passage de la première bande** de papier à travers l'ensemble des axes.
3. **Mise en route marche à coup** (fonctionnement saccadé) pour valider la trajectoire initiale.
4. **Affinage des paramètres** jusqu'à atteindre la performance souhaitée.

Théoriquement, cette séquence forme une route menant à un réglage optimal. Cependant, les critères pour juger de l'optimalité restent flous et varient selon les régleurs. En effet, chaque régleur se fie à sa propre expérience et à ses compétences. Une même machine comportant le même papier ne sera pas réglée de la même façon suivant les régleurs.

Dans tous les cas, le format client et les caractéristiques du papier (grammage, épaisseur, traitement de surface) doivent impérativement être respectés. Il en résulte que, pour un même format, on dispose ainsi d'une plage de réglages admissibles, sans qu'il soit aisé de déterminer laquelle est la meilleure tant que les spécifications sont respectées.

Effectivement, les indicateurs d'un réglage optimal restent vagues et diffèrent selon chaque régleur. Pour l'un, un réglage est satisfaisant si la vibration ressentie demeure minimale ; pour l'autre, c'est le timbre du son à l'arrache qui sert de référence.

En conséquence, aucun régleur n'est en mesure de conclure de manière entièrement objective sur la qualité d'un paramétrage.

De plus, la RS26 est une machine polyvalente : chaque client peut commander des sacs de formats très variés, voire des grammages de papier différents. Les plages de réglages diffèrent donc considérablement d'un lot à l'autre.

En pratique, lorsqu'un client réclame un format spécifique, les paramètres initiaux du réglage vont changer. Puis, comme dans un effet de cascade, tous les autres paramètres doivent suivre pour éviter toute incohérence (glissements, plis, contraintes tardives) et empêcher le papier de se balader dans la machine.

En résumé, il n'existe donc pas de réglage universel : chaque paramétrage est propre à un format et à un matériau donné, ce qui complique grandement l'analyse et la standardisation du processus.

Heureusement, plusieurs généralités peuvent être notées : une plage de réglage existe forcément pour un format spécifique, un fonctionnement optimal en haute cadence peut être étudié en basse cadence pour faciliter l'analyse des données, selon **Georges MATHE** : expert régleur machine.

5 Analyse des signaux : capteur présent et ajouté

Pour poser une base méthodologique solide, nous devons analyser plusieurs types de signaux. L'objectif est de déterminer si ces signaux permettent de distinguer les différents états de fonctionnement de la machine. Nous consacrons donc cette section à l'étude comparative des signaux suivants :

- **Données Simotion** : extraction du couple moteur, position, vitesse, accélération de chacun des axes à 4 ms, soit 250 Hz.
- **Signaux vibratoires** : enregistrement de l'accélération brute à 48 kHz.
- **Signaux acoustiques** : acquisition du son brute sans filtrage à 96 kHz.

Remarques : Pour la preuve de conception et la reproductibilité des résultats, les machines étudiées sont toutes des modèles RS26.

Dans cette section, nous présentons ainsi les différentes données extraites afin de les analyser.

5.1 Données Simotion

Contexte

Les données *Simotion* sont exploitées directement par les automates *Siemens Simotion*. Cet automate, comme expliqué dans l'**annexe tableau 1**, constitue le cœur de la commande moteur. C'est pourquoi dans le cas d'une étude profonde sur les réglages machines, il est logique que cette plateforme attire notre attention. Il est donc possible d'étudier une multitude de variables moteurs tel :

- le **couple**, l'**accélération**, la **vitesse** et la **position** du moteur
- la consommation **électrique** ainsi que la **température**
- etc...

Par ailleurs, l'intégration native aux automates existants, sans ajout de capteurs, constitue un atout majeur de Simotion. Sa capacité à traiter et échanger en continu les données de couple, vitesse et position en fait le candidat idéal pour une analyse approfondie en temps réel.


Physique du couple moteur

La réussite de notre étude repose d'abord sur un protocole rigoureux d'acquisition et de traitement des données. Avant toute modélisation, nous devons définir les signaux pertinents, mettre en place un prétraitement adapté (filtrage, normalisation, fenêtrage) et extraire des caractéristiques discriminantes. Sélectionner les bonnes méthodes analytiques et identifier les indicateurs les plus informatifs constitue l'enjeu central de cette phase d'analyse.

Ainsi, nous avons étudié les machines de près et avons conclu sur le fait que le couple moteur des différents axes sont les données les plus discriminantes, nous permettant de clairement distinguer un bon d'un mauvais réglage (**figure 6**).

En effet, lorsque la bande papier est entraînée par un moteur, le couple reste stable en fonctionnement normal, tandis qu'un accoup – par exemple au moment de l'arrachage pour former un sac – se traduit par un pic de couple.

Enfin, la **figure 6** illustre l'impact d'un mauvais réglage sur le couple moteur : on y observe un pic prononcé et une tendance erratique, typiques d'une arrache prématurée.



(a) : bon réglage

(b) : mauvais réglage, avance de 6 impulsions

**figure 6 : exemple de l'impact d'un mauvais réglage sur le couple d'un moteur lors de la formation d'un sac (Axe appel de sortie - AppS)
superposition de 50 échantillons de la même machine sur le même réglage**

Observation : Nous voyons, non seulement, une différence visuelle au niveau de la forme de la courbe mais nous observons notamment un couple pic subit d'une différence de 6 Nm ! Dans le cas d'une bande papier, 6 Nm représente une réelle différence.

Caractéristique et intégration

Comme mentionné précédemment, *Simotion* est une plateforme de communication temps réel entre automates dédiée au contrôle fin des moteurs. L'acquisition des données via *Simotion* est naturellement limitée par la fréquence d'échantillonnage de l'automate, fixé à 4 ms soit 250 Hz. Même si, d'un point de vue traitement de signal, 250 Hz semble insuffisant, nous avons prouvé dans les parties suivantes (**chap V. 2.2**) que cette résolution est suffisante pour effectuer un diagnostic précis.

La collecte des données *Simotion* est particulièrement intuitive. Le logiciel *Simotion Scout* permet ainsi d'extraire les variables qui nous intéressent afin de les afficher dans un graphique sous la forme d'un oscillogramme (**figure 7.a** et **7.b**). L'export au format (.csv) s'effectue en quelques clics, facilitant la mise en place d'un prototype local. De plus, la remontée des données se retrouve aussi vers d'autres protocoles de communication comme OPC UA.




figure 7.a : Insertion des variables voulues pour un traçage en temps réel (logiciel : Simotion Scout v5.6)




figure 7.b : Exemple d'affichage de variables en temps réel sur une machine test, RS26 (logiciel : Simotion Scout v5.6)

Remarques : Certaines machines ne disposaient pas des ports de communications nécessaires pour remonter le couple d'une adresse spécifique. D'autres, les automaticiens n'avaient pas fait remonter les valeurs dès la programmation de la machine. Nous avons donc dû configurer quelques ports dans le but d'accéder à la variable du couple moteur (figure 8).




figure 8 : modification du drive pour remonter la variable voulue, sur une RS26 (logiciel : Simotion Scout v5.6)

5.2 Signaux vibratoires

Contexte

En industrie, la vibration figure parmi les grandeurs physiques les plus étudiées pour le diagnostic machine. Par exemple, dans une fraiseuse, l'analyse vibratoire permet de détecter des anomalies ou d'estimer la durée de vie restant de l'outil.

Notre cas est similaire : lors de la formation d'un sac, un choc mécanique est généré car une petite partie de la bande est arrachée pour former le sac. Ainsi, l'étude de ses vibrations s'avère particulièrement intrigante. De plus, contrairement aux signaux acoustiques, la vibration ne se propage que par contact matériaux-matériaux. Or, la plupart des composants sont construits à partir d'éléments rigides comme l'aluminium, rendant la perte d'absorption vibratoire minimale (**figure 9**). Ceci nous autorise à varier notre étude vibratoire sur différents emplacements du capteur dans la machine (**figure 12**) !

Physique vibratoire de la machine

Dans les cas des machines à sacs comme la RS26, la question n'est pas de savoir si la présence d'un accoup est une anomalie (comme dans la détection d'anomalie d'usinage) mais plutôt si la mesure de la vibration attendue de l'accoup est anormal, si oui à quel point.

Vu que l'accoup est prévisible à un instant t périodique, l'IA aura pour mission de savoir si la forme de l'accoup est anormale ou pas, tout comme les signaux issus de *Simotion*.




figure 9 : processus de transmission de vibration avant et après l'arrache

Nous pouvons montrer un aperçu de la vibration qu'engendre l'arrache du papier (**figure ci-dessous**).




figure 10 : vibration engendré par la formation d'un sac lors de l'arrache
(a) : réglage machine sans défaut, (b) : réglage machine avec arrache trop tôt

Caractéristique et intégration

HolwegWeber ne disposant pas de capteurs de vibrations, nous avons sollicité l'intervention de plusieurs acteurs : Pr. Knittel, Sick et Pepperl Fuchs. Chacun ayant des capteurs différents, les implémentations ont donc varié suivant les fournisseurs (**tableau 2**).

Fournisseur	Modèle	Configuration	Communication	Fréquence d'échantillonnage
Pr. Knittel	-	Matlab	USB	48 kHz
SICK	IOLA2US-01101	SOPAS Engineering Tool	IO-Link MASTER USB	3.2 kHz
Pepperl & Fuchs	VIM32PL-E1AC8-0RE-IO-1V1401	PACTware	IO-Link MASTER USB	1 kHz
	VIM32PP-E7DC8-0RE-IO-1V1401	par serveur web (adresse IP)	IO-Link BLOB via MQTT annexe figure 12	64 kHz

tableau 2 : description des différents capteurs de vibration utilisés

Pour la suite du projet, nous ne retenons que les capteurs surlignés ci-dessus en **vert**. D'après nos essais, les autres capteurs **rouges** présentent une fréquence d'échantillonnage trop faible pour détecter une quelconque variation (**figure ci-dessous**). De plus, l'IO-Link MASTER USB applique un filtrage par moyenne mobile le rendant inadapté à notre application.




figure 11 : sortie du capteur IOLA2US-01101 - fréquence d'échantillonnage trop faible (source : logiciel SOPAS engineering tool - Sick)

Sans entrer dans le détail de chaque position, nous retenons deux emplacements clés (identifiés sur la **figure 12, ci-dessous**) :

- **(a)** : Cet emplacement est le plus proche de l'arrache, le rendant plus sensible au choc.
- **(e)** : Cet emplacement est le plus proche du mandrin, une zone qui sollicite beaucoup d'efforts sur la bande papier.

Les emplacements restants **(b)**, **(c)**, **(d)** n'ont pas été placés sur les pièces subissant le plus de vibrations. Dans leur cas, la vibration de la machine perturbe la qualité du signal, les rendant inaptes à être exploiter davantage.




figure 12 : les différents emplacements testés pour la vibration
(source : campagne de mesure sur RS26 client Mettler chez Holweg, Molsheim)

5.3 Signaux acoustiques

Contexte

L'analyse du domaine acoustique représente à lui-même une profession à part entière. Le traitement de signal sur le son nécessite des compétences et des années d'études spécialisées. Pourtant, ce défi alimente aussi notre envie de prouver le contraire !

L'exploitation du son des machines industrielles relève des enjeux significatifs le rendant inexploitable dans la réalité. Non seulement la machine doit être isolée des sons perturbateurs mais cela suggère aussi que la machine doit opérer en autonomie, sans la présence d'un humain qui pourrait influencer l'environnement d'opération.

Physique acoustique de la machine

L'application de l'analyse sonore reste tout de même une étude importante car elle soulève le domaine de l'innovation. Elle reflète des phénomènes mécaniques caractéristiques qui ne serait pas perceptible par d'autres signaux (Wassim Zaman et al., 2025 [24]).

Ainsi, lorsque les régleurs ajustent les machines à l'oreille, ils détectent par expérience les anomalies : un frottement anormal ou un claquement inhabituel. Plus précisément, les régleurs experts ajustent les réglages selon le timbre du son émis lors de l'arrachage du papier (selon **Georges MATHE**). Cette capacité humaine s'explique par la faculté au cerveau à filtrer naturellement les bruits de fond et à isoler les signatures sonores pertinentes.

Remarques : Dans notre cas, l'analyse acoustique reste contraignante. Si la machine RS26 produit un son qui est perceptible et analysable, ce n'est pas le cas pour toutes les machines comme les ECOMs qui produisent un son assourdissant, rendant l'analyse sonore difficilement possible.

Caractéristique et intégration

Comme évoqué précédemment, l'analyse acoustique constitue un domaine à part entière, tant par ses enjeux industriels que par la richesse de sa signature sonore. Or, les fournisseurs ne commercialisent pas de capteurs sonores directionnels adaptés à nos besoins. Heureusement, le Pr. Knittel nous a fourni deux microphones d'acquisition haute résolution et directionnel, capables d'échantillonner à 96 kHz, ce qui nous a permis de mener à bien nos campagnes de mesures. Sans entrer dans le détail de chaque position, nous retenons un emplacements clé (identifiés sur la **figure 13, ci-dessous**) :

- **(a) :** Cet emplacement est le plus proche de l'arrache, rendant l'analyse du son plus facile car le micro directionnel filtre un minimum le son parasite.




figure 13 : les différents emplacements de capteur testés pour le son
(source : campagne de mesure sur RS26 client Mettler chez Holweg, Molsheim)

Remarques : Suivant les machines et le sac produit, même si un réglage est optimal, le son généré peut varier. Dans le cas **(b)**, la machine génère un bruit d'arrachement trop fort ce qui saturait le capteur (**figure 14**). Nous avons donc dû éloigner le capteur de sorte à éviter cette saturation (**d**), ce qui a réduit la propreté et la netteté du signal.




figure 14 : saturation du capteur de son pour la situation (b) de la figure 13

Nous pouvons montrer un aperçu du signal acoustique (**figure ci-dessous**).




figure 15 : comparaison du signal acoustique entre bon et mauvais réglage
(source : RS26 client Mettler chez Holweg, Molsheim)

(a) : réglage machine sans défaut, (b) : réglage machine avec pression galet rattrapage trop élevé

Observation : Une distinction entre les différents signaux acoustiques suivant quelques anomalies est ainsi possible. Cependant, l'analyse reste difficile, nécessitant une expertise du domaine.

6 État de la machine

En soi, une machine à sac présente plusieurs états de fonctionnement : la phase où il tire le papier, la phase où il forme le boyau, puis ensuite la phase où il arrache le sac. Mais plus simplement, on pourrait juste résumer les différents états de la machine en deux : le moment où il tire et le moment où il arrache (**figure 16**).




figure 16 : les différents états de la machine d'après le signal acoustique
(source : RS26 client Mettler chez Holweg, Molsheim)

Ainsi, contrairement aux machines d'usinage comme la fraiseuse qui présente en général un seul état d'usinage (suppression de matières constante), une machine comme la RS26 nécessite une étude sur plusieurs moments clefs.

D'après de nombreuses études effectuées, nous avons jugé que le moment critique, soit le moment où la machine arrache le papier, présente le plus de caractéristiques discriminantes permettant une meilleure distinction entre un fonctionnement optimal et non-optimal.

7 Les défauts

Les anomalies observées sur les machines à sacs diffèrent de celles des centres d'usinage. Là où une fraiseuse présentera des défauts de qualité de coupe ou une usure prématurée de l'outil, la RS26 est soumise à des phénomènes spécifiques variés :

- **Endommagement prématuré** d'éléments tels que le galet de rattrapage ou les pinces d'arraches et de maintien (ex : galet de rattrapage, pince d'arrache)
- Production de **sacs non conforme** au format
- **Casse-papier** dues aux efforts excessifs
- Configurations limites où la machine **fonctionne normalement en bas régime finit par produire une casse-papier** lors de l'accélération

Cette diversité complique la catégorisation et rend la détection plus délicate, car chaque type de défaut nécessite des indicateurs et des capteurs adaptés.

Il est aussi important de noter qu'un défaut n'est pas forcément singulier. Plusieurs défauts peuvent se manifester simultanément, ce qui complique la détection d'anomalie. De plus, il faut aussi rappeler que les origines des défauts ne sont pas homogènes suivant les machines, l'environnement, le format du papier ainsi que les propriétés du papier.

Enfin, la capacité à détecter une anomalie dépend fortement de l'emplacement du capteur. Pour les mesures vibratoires, un positionnement inadapté est en incapacité à détecter le choc généré lorsqu'on augmente la tension d'appel de sortie (**AppS**) durant l'arrache .

Cependant, si les vibrations ne peuvent pas être ressenties à tous les endroits, l'étude du couple moteur sur *Simotion* constitue un indicateur fiable pour repérer cette anomalie (**figure 17**).




figure 17 : comparaison entre un réglage machine sans défaut (a), (c) et réglage machine avec augmentation de la tension d'appel de sortie (AppS + 10%) (b), (d)

(a), (b) : vibration sur la localisation (a) figure 12

(c), (d) : Couple moteur AppS extrait de *Simotion*

8 Définition de la problématique

Comme nous l'avons montré précédemment, le choix des indicateurs et l'emplacement des capteurs doivent être rigoureux pour caractériser le comportement de la machine. La fusion multivariée des signaux (vibrations, acoustique, couple moteur...) s'avère non seulement possible, mais recommandée. Cette complexité de traitement nous conduit à privilégier une solution basée sur l'intelligence artificielle avec un apprentissage supervisé ou semi-supervisé plutôt que par renforcement, puisque nous ne disposons pas d'un jumeau numérique ni d'une boucle de rétroaction complète, et que nombre de réglages restent manuels.

Notre objectif est de concevoir un modèle d'IA capable de proposer des réglages optimaux selon le type de papier et la configuration de la machine. Avant toute modélisation, nous mènerons une étude exploratoire pour expliquer l'origine des cassures et identifier les caractéristiques les plus discriminantes.

Le déroulement de cette étude se fait en quatre phases :

- **Transformation des données** : collecte synchronisée et prétraitement (filtrage, normalisation, fenêtrage)
- **Recherche exploratoire** : extraction des caractéristiques, identification des indicateurs clés et formatage des données exploitées
- **Évaluation des modèles** : mise en place de plusieurs métriques (robustesse, généralisabilité, précision) dans le but de proposer des modèles d'IA implémentable
- **Implémentation embarquée** : développement et déploiement d'une solution robuste sur système *Edge* en condition réelle

Chapitre IV : État de l'art

1 Introduction

La détection d'anomalie ou de valeur aberrante est un domaine prometteur dans l'industrie puisque de nombreuses données sont déjà collectées continuellement mais il est encore difficile de les exploiter. Si l'utilisation d'images (Yeqi Liu et al., 2020 [1]) est envisageable, ce champ est déjà bien maîtrisé par les experts, ce qui serait intéressant mais nécessitent une puissance de calcul conséquente. En revanche, l'étude des anomalies par l'analyse des vibrations apparaît plus prometteuse, notamment parce qu'elle requiert moins de puissance de calcul ; un avantage considérable pour les systèmes embarqués (Alessandro Baldini et al., 2023 [2]). M.A. Zakeri Harandi et al., 2025 [3], mentionne notamment que l'analyse des signaux acoustiques contient à la fois une meilleure compréhension du fonctionnement d'une machine industrielle mais aussi de son processus, rendant les données sonores plus représentatives.

Par ailleurs, il est parfois inutile d'investir dans de nouveaux capteurs, car des données sont déjà disponibles mais non utilisées à des fins de détection d'anomalies. Ces arguments sont particulièrement pertinents pour les industriels de demain, auprès desquels nous serons amenés à intervenir.

Ce document est structuré de la manière suivante : la première partie propose un rappel sur les différentes approches utilisées dans la détection d'anomalie, suivie par une introduction sur l'utilisation des autoencodeurs (ou autoencoder en anglais). La troisième partie dresse un bilan des méthodes exploitant l'espace latent des autoencodeurs pour la classification, tandis que la quatrième partie traite des différentes techniques pour le diagnostic en utilisant des approches supervisées avancées. Enfin, la dernière partie expliquera les méthodes employées pour efficacement généraliser une IA dans le cadre industriel.

Sommaire

Chapitre IV	État de l'art.....	28
1	Introduction.....	28
2	Les approches actuelles d'IA.....	29
3	Utilisation d'autoencodeur.....	30
4	Exploitation de l'espace latent.....	32
5	Généralisation de l'IA dans le cadre industriel.....	33


2 Les approches actuelles d'IA

Il y a pléthore de méthodes pour détecter des anomalies. On peut cependant les classer en 3 types : supervisées, semi-supervisées et non supervisées.

Les techniques **supervisées** permettent d'atteindre de meilleures performances lors de l'entraînement, cependant elles risquent généralement de sur-ajuster (overfitting) ces anomalies, ce qui entraîne une mauvaise généralisation aux nouveaux outliers.

Les approches **semi-supervisées** offrent une solution plus flexible en tirant parti à la fois des données étiquetées et non étiquetées (Oliver et al, 2018 [4]). Cependant, malgré leurs promesses (Oliver et al., 2018 [4] ; Zhou et al., 2022 [5]), ces méthodes dépendent toujours d'une certaine quantité de données labellisées, ce qui reste contraignant. Ainsi, la tâche de détection d'anomalies dans les séries temporelles est généralement formulée comme un problème non supervisé (Su et al., 2019 [6]). En effet, puisque les anomalies surviennent rarement, l'annotation des données devient difficile et coûteuse ; cela rend l'apprentissage non supervisé plus approprié malgré l'exposition à des défis supplémentaires tels que l'ajustement complexe des hyperparamètres.

Finalement, les méthodes en **non-supervisées** qui ne nécessitent pas de données labellisées. Selon la revue de littérature de Nesryne Mejri et al., 2024 [7], il existe alors 5 méthodes principales :



1. Méthodes basées sur le **clustering** : Ces méthodes regroupent les données en clusters et identifient les points qui ne s'intègrent pas bien dans ces groupes comme des anomalies. On peut également détecter les anomalies à l'aide d'une distance comparée à un seuil. C'est le cas, par exemple, de la description de données par vecteurs de support (SVDD) (Tax & Duin, 2004 [8]), qui mesure la distance par rapport aux centroïdes. Cette approche a notamment été exploré par Kuigeng Lin et al., 2024 [9], expliquant ainsi que la SVDD, développé à partir de la SVM, permet d'obtenir des résultats satisfaisants tout en réduisant les désavantages d'une méthode moins évolutive.
2. Méthodes basées sur **l'estimation de densité** : Ces approches évaluent la densité des données dans l'espace de caractéristiques. Les points de données situés dans des régions de faible densité sont considérés comme des anomalies, car ils sont moins fréquents par rapport aux autres points.
3. Méthodes basées sur la **distance** : Ces méthodes mesurent la distance entre les points de données et identifient ceux qui sont éloignés des autres comme des anomalies. Cela peut inclure des techniques comme les k-plus nearest neighbors (k-NN).
4. Méthodes basées sur la **reconstruction** : Ces techniques reconstruisent les données à l'aide de modèles et comparent les données reconstruites avec les données originales. Les points présentant des erreurs de reconstruction élevées sont considérés comme des anomalies, Marco Pota et al., 2023 [10].

5. Méthodes basées sur la **prévision** : Ces approches utilisent des modèles de prévision pour prédire les valeurs futures et détecter les anomalies en identifiant les écarts significatifs entre les valeurs observées et les valeurs prédites. Yuan Mei et al., 2016 [11], ont utilisé cette technique pour estimer la durée de vie restante des moteurs d'avions, démontrant une prédiction correcte, précise et robuste.

Lors de nos recherches, une autre méthode a suscité notre intérêt. K Manjunath et al., 2023 [12], suggèrent de transformer les **spectres en images** et de les analyser à l'aide d'outils de *Deep Learning* (DL), comme les réseaux de neurones convolutionnels (CNN, expliqué en **annexe définition 9**), conçus pour l'analyse d'images. Cette méthode a l'avantage d'extraire automatiquement les *features* des signaux, de réduire la quantité des données d'entraînement grâce à l'utilisation du *Transfer Learning* ainsi que d'être particulièrement robuste aux non-linéarités et au bruit. Ils parviennent donc à obtenir d'excellent résultat à moindre coût et en temps réel ce qui semble tout à fait approprié à l'embarqué.

En complément, M.A. Zakeri Harandi et al., 2025 [3], a piqué notre intérêt. D'après eux, les techniques actuelles d'extraction de caractéristique temps-fréquence (TFR) ont du mal à diagnostiquer correctement les signaux, de part le caractère transitoire et non-stationnaire du son. C'est pourquoi ils transforment les signaux en images scalogrammes.

Toutefois, l'exploitation des données acoustiques nécessite cependant, un preprocessing conséquent. Même si l'exploitation des caractéristiques basées sur le scalogramme est une idée qui a fonctionné pour M.A. Zakeri Harandi et al., 2025 [3], son preprocessing reste néanmoins complexe, nécessitant une connaissance du domaine du traitement de signal (Ruqiang Yan et al., 2023 [13]).

Ainsi, pour diagnostiquer correctement les signaux sonores, Md Shofiqul Islam et al., 2025 [14], utilise le melspectrogramme afin de mieux représenter le son à l'ouïe humaine. En effet, encore aujourd'hui l'expertise humaine reste meilleure pour les applications spécialisées, augmentant l'intérêt pour cette image basée sur les caractéristiques temps-fréquence.

Ces études montrent que l'exploitation des CNN facilite l'assimilation des détails visuels, autrement difficile à appréhender. En effet, Hao Huang et al., 2024 [15], signale que la combinaison d'un CNN et d'un LSTM améliore la captation des motifs et des caractéristiques locales, renforçant ainsi l'intérêt pour les couches CNN.

3 Utilisation d'autoencodeur

L'autoencodeur (AE) est une architecture de réseau de neurones conçue pour apprendre une représentation compacte des données d'entrée, pour les reconstruire en sortie. Son fonctionnement se décompose en deux parties (voir **figure 18**):

- **Encodeur ϕ** : série de couches qui réduit progressivement la dimensionnalité des données $\mathbf{x}$ et extrait leurs caractéristiques essentielles
- **Décodeur φ** : symétrique à l'encodeur, il reconstruit la donnée d'entrée $\mathbf{x}$ à partir du vecteur latent ($\mathbf{z}$) pour ressortir la donnée de sortie $\hat{\mathbf{x}}$




figure 18 : schéma d'un autoencodeur
(source : Marco Pota et al., 2023 [10])

En s'entraînant ainsi à reconstruire les données à disposition, l'AE apprend les motifs récurrents et minimise l'erreur de reconstruction à chaque boucle. Les avantages de ce modèle réside ainsi dans son absence de besoin en donnée étiquetée et dans son efficacité à comprimer les données en une dimension bien plus faible : le vecteur d'espace latent $\mathbf{z}$. Ce vecteur constitue un résumé compact des données, pouvant servir à classifier et détecter des anomalies en supervisé ou en semi-supervisé (technique précédemment décrite dans le **chap IV. 1**).

Les AE ont été premièrement introduits par Rumelhart et al., 1986, pour résoudre le problème de *backpropagation without a teacher*, c'est-à-dire entraîner un réseau de neurones si aucun label n'était présent. En 2013, Diederik P. Kingma et al. introduit la notion de *variational* dans l'AE : le VAE. Cette nouvelle innovation change la structure de l'espace latent pour ne plus être un code déterministe mais une distribution gaussienne de la donnée d'entrée, permettant de la régulariser et éviter un sur-apprentissage. Une fusion avec des couches LSTM est possible pour ajouter une dimension temporelle au modèle (**figure 19**).




figure 19 : les différentes topologies des AE et VAE selon Davide Azzalini et al., 2025 [16]
les encodeurs sont en violet, les décodeurs en rose et l'espace latent en jaune

Un autoencodeur (AE) se décline principalement en trois grandes familles :

- **AE classique** : Encode l'entrée en un vecteur latent de taille réduite puis la reconstruit. Il apprend une représentation comprimée des données, utile pour mémoriser la structure globale sans en modéliser la distribution
- **Variational Autoencoder (VAE)** : Remplace le code déterministe par une distribution gaussienne dans l'espace latent. Chaque échantillon est alors représenté par une paire (μ, σ) , ce qui permet d'estimer la probabilité de normalité d'une observation et de régulariser l'apprentissage pour éviter le sur-apprentissage
- **Autoencodeur récurrent (RAE / LSTM-AE / LSTM-VAE)** : Intègre des couches RNN ou LSTM dans l'encodeur et/ou le décodeur afin de capturer les dépendances temporelles. En plus de reconstruire les fenêtres passées, il peut prédire les séquences futures, ce qui le rend particulièrement adapté aux séries dynamiques

David Azzalini et al., 2025 [16], ont montré que les VAE et LSTM-VAE obtiennent de meilleurs résultats : les F1-scores sont respectivement de 0,854 et 0,901, contre 0,823 pour l'AE. Ils soulignent que la complexité accrue de ces architectures se traduit ainsi par des performances supérieures.

4 Exploitation de l'espace latent

Pour diagnostiquer un système, on définit un score d'anomalie qui combine à la fois la confiance du modèle et la gravité de l'écart observé. Plutôt que de se limiter à l'erreur de reconstruction, Asif Ahmed Nelay et Maxime Turgeon, 2024 [17], exploitent l'espace latent, plus robuste face aux bruits et variations subtiles. En extrayant le vecteur de l'espace latent de son AE, une analyse profonde sur la compréhension de son modèle peut être faite. En effet, si d'après la représentation 2D de l'espace latent, les données sont séparées sous forme de cluster, alors le modèle a réussi à comprendre que chaque label est différent. Dans le cas contraire, une optimisation supplémentaire doit être mise en place pour aider à séparer chaque cluster (**figure 20**).




figure 20 : représentation de l'espace latent sur le MNIST dataset
(source : Asif Ahmed Nelay & Maxime Turgeon, 2024 [17])

5 Généralisation de l'IA dans le cadre industriel

Si un réseau de neurones peut exceller sur la donnée dont il a été entraîné, il perd souvent en fiabilité et en généralisabilité dès qu'on le confronte à une nouvelle donnée (Lei Le et al., 2018 [20]). En effet, lors de la phase d'entraînement d'une IA, les poids contenus dans les neurones sont modifiés constamment par l'algorithme mis en place. Cependant, durant la phase de validation où l'IA juge la donnée d'entrée, ces poids ne sont plus mis à jour. C'est ce moment critique qui empêche un modèle d'IA de s'adapter à de nouvelles données même si celles-ci appartiennent à la même classe.

Cette partie se concentre ainsi sur les techniques et les méthodes adoptées afin de mieux généraliser une IA. Plusieurs approches sont connues pour remédier à ce problème : transfer learning et incremental learning.

Mohammed Alduais et al., 2025 [19], appliquent le transfer learning pour pallier le manque de données étiquetées. Ils reprennent un modèle pré-entraîné sur un large jeu de données et réutilisent ses couches convolutives en fine-tuning sur un jeu spécialisé (**figure 21**). Cette approche accélère l'adaptation, mais présente deux limites majeures : elle exige un pré-entraînement sur un volume de données conséquent, et elle ne confère pas de généralité accrue au modèle, qui reste avant tout spécialisé à son nouveau domaine.




figure 21 : vue d'ensemble de la méthode transfer learning. Le transfer learning commence par utiliser un modèle pré-entraîné pour le spécialiser à un nouveau jeu de donnée (source : Mohammed Alduais et al., 2025 [19])

Muhammad Abdullah Hafeez et al., 2023 [18] a suscité notre intérêt pour leur avis sur l'*incremental learning* (ou apprentissage incrémental). Cette méthode repose sur la base que l'IA va être entraînée au fur et à mesure (**figure 22**).




figure 22 : les différents processus durant la phase d'entraînement et incremental learning (source : Yu Cheng et al., 2018 [21])

Cependant, cette technique — bien que prometteuse — présente des désavantages notables.

“L’un des principaux obstacles à la mise en place d’un véritable apprentissage incrémental dans les modèles de Deep Learning est le phénomène dit *Catastrophic Forgetting*. Par définition, ces modèles possèdent des paramètres ajustables — les poids — qui sont optimisés de manière itérative lors de la phase d’entraînement. Ces poids appris représentent collectivement la fonction que le modèle a apprise. En contexte incrémental, dès qu’un nouveau jeu de données lui est présenté, le modèle tente de l’assimiler, au risque de perdre ses connaissances précédentes.” selon Muhammad Abdullah Hafeez et al., 2023 [18] : partie Introduction.

Ainsi, pour qu’un modèle soit qualifié de véritablement incrémental, plusieurs critères doivent être remplis :

- **Résistant au Catastrophic Forgetting** : les performances sur les anciennes classes ne doivent pas être dégradé
- **Indépendance des phases de réapprentissage** : le modèle ne requiert pas un réentraînement global de toutes les données pour maintenir sa performance
- **Extensibilité sans limite prédéfinie** : l’architecture doit pouvoir intégrer des nouvelles classes sans atteindre une limite avec l’augmentation du nombre d’incrément
- **Croissance de la taille du modèle** : lors de la phase d’incrément, le modèle en vue de la complexité des données, doit augmenter sa taille du réseau, avec un faible taux de croissance

En résumé, les différents critères mentionnés au-dessus, rend l’implémentation d’un incremental learning comme complexe et nécessitant à la fois une puissance de calcul conséquente mais aussi une expertise du domaine.

Chapitre V : Phase exploratoire de recherche

La phase exploratoire constitue la majeure partie du travail effectué. Elle démontre les différentes méthodes utilisées ainsi que les solutions optimales apportées. Durant ce travail de recherche, nous montrons que la complexité et le volume des signaux ne nous permettent pas de mettre en œuvre une solution de *machine learning* simple comme un *Kmeans*, *KNN* ou un *SVM*. Ainsi, les modèles utilisés sont des modèles de *deep learning* créés, paramétrés, entraînés et optimisés par nos soins.

1 Preprocessing

Un prétraitement ou preprocessing est une étape rigoureuse et primordiale. Il permet non seulement de réduire le sur-apprentissage mais aussi le temps d'entraînement tout en augmentant l'efficacité du modèle. En effet, une IA ne comprend pas le concept de proportion comme nous le comprenons. Par exemple, sachant que le calcul du biais et du poids est géré de manière autonome par des calculs algébriques, la différence entre 1 et 5 est grande en comparaison à 0.1 et 0.5 même si on retrouve un facteur 5.

Le *preprocessing* est donc une étape et non une méthode, il inclut ainsi pléthore de manière de l'effectuer en fonction du type de donnée et son contexte. Dans notre situation, les signaux présentés (couple, vibration, son) démontrent tous des amplitudes diverses rendant la compréhension complexe.

Remarques : Les amplitudes des signaux sont dépendantes de plusieurs facteurs : la machine, les réglages, l'état de la machine, la cadence, le format du sac, les caractéristiques du papier etc...

Un preprocessing est donc obligatoire dans le but de généraliser les données.

Nous avons ainsi effectué du preprocessing comme suit :

- **Moyenner le signal :** recentrer le signal autour de 0
- **Normalisation :** normaliser les amplitudes sur une plage fixe, typiquement $[-1;1]$ ou $[0;1]$ (**figure 23**)
- **Fenêtrage :** homogénéiser les événements par des échantillons de temps réduit pour ne capturer que les moments importants (**figure 24**)




figure 23 : Signal index n°5 **sans** normalisation (gauche) et **avec** normalisation (droite)




figure 24 : Exemple de fenêtrage pour capturer un moment spécifique

À partir de ce point, nous considérerons systématiquement que les données utilisées dans les sections suivantes ont fait l'objet du meilleur prétraitement afin de concentrer l'étude sur les résultats méthodologiques et expérimentaux.

2 Approches pour Simotion

Les données extraites de *Simotion Scout* sont à la fois riches et complexes, car elles regroupent le couple de chacun des six axes moteurs. En pratique, détecter une anomalie ne se limite pas à analyser un seul axe : il faut tenir compte de l'ensemble des six séries temporelles, chacune apportant une information spécifique sur le comportement de la machine. Le problème se situe donc dans un cadre d'un modèle multivarié. De ce fait, les méthodes employées dans la partie ci-présente sont sujets d'une complexité accrue, nécessitant de l'innovation dans le but de pallier ce problème.

Remarques : Nous avons exploré un total de vingt méthodes différentes par type de données. Pour éviter de surcharger et noyer le rapport, nous avons décidé de n'en présenter que deux. Néanmoins, un bilan est dressé dans la partie (**Chap V. 5**) pour démontrer les diverses méthodes exploratoires ainsi qu'émettre une conclusion sur le modèle optimal recommandé.

2.1 Autoencodeur : reconstruction multi branche

La mise en œuvre de cette approche a mobilisé beaucoup de temps, car implémenter une IA à travers les outils intégrés aux automates Holweg constituait un défi motivant. En effet, pouvoir concevoir une IA directement déployable dans l'automate, sans ajouter de capteur ni augmenter les coûts de production, représentait un objectif transversal.

L'autoencodeur est un modèle déjà éprouvé et mis en œuvre à plusieurs reprises : Hackathon UNISTRA 2024, projet de M2 sur la détection d'anomalies d'usinage. Notre expérience dans ce domaine a donc facilité la création et le déploiement d'une solution par reconstruction.

Toutefois, les données multivariées ont véritablement freiné les délais d'implémentation. En effet, nous avons passé plus d'une trentaine d'heures à optimiser notre IA, en ajustant tous les hyperparamètres connus, mais aussi l'architecture du modèle, la taille et la forme des échantillons, ainsi que les prétraitements appliqués.

2.1.1 Méthode

L'idée derrière l'autoencodeur était de pouvoir envoyer en entrée les données *timeseries* des couples de chaque axe. Le modèle d'IA se charge ainsi de compresser ces données, puis de les reconstruire aussi fidèlement que possible. La phase suivante a consisté à analyser la compréhension de l'IA par le biais d'une étude statistique de l'espace latent.

En effet, même si l'erreur de reconstruction constitue une métrique de performance et/ou de confiance, notre expérience avec les autoencodeurs nous amène à la remettre en question. Cette erreur n'étant qu'une différence de reconstruction, nous nous sommes concentrés sur l'espace latent pour examiner plus finement la manière dont le modèle appréhende les données. Plus précisément, nous avons étudié la distance de Mahalanobis (voir **annexe définition 3**) entre échantillons pour diagnostiquer si un signal est mauvais ou sain (**figure 25**).




figure 25 : Étude de la distance de Mahalanobis sur l'espace latent
(source : Marco Pota et al., 2023 [10])

Bien que la distance de Mahalanobis soit intéressante à étudier, l'autoencodeur reste sensible aux variations internes des données. De plus, comme la variabilité est indépendante d'un signal à l'autre, la reconstruction est biaisée : avec un seul autoencodeur, les branches de l'encodeur, du décodeur et l'espace latent sont partagées.

Autrement dit, le signal dont l'amplitude varie le plus est privilégié pour la reconstruction, au détriment des autres signaux.

En conséquence, un ou deux signaux sont mal reconstruits, ce qui diminue la fiabilité du modèle et la confiance que nous accordons à l'espace latent, car celui-ci ne représente plus tous les signaux de manière équitable (**figure 26**).

En bref, un axe très « bruyant » ou à forte amplitude écrase dans l'espace latent les signaux ayant moins de variance. Ce phénomène apparaît dans la fonction de coût : en cherchant à minimiser l'erreur, corriger prioritairement la reconstruction du signal le plus bruyé permet une convergence plus rapide.




figure 26 : Résultat de la reconstruction d'un autoencodeur sur les données multivariés

Observation : Comme suggère la **figure ci-dessus**, la reconstruction n'a été privilégiée uniquement par les axes *torque 4* et *torque 3*, qui démontre notamment une plus grande variance d'amplitude.

Pour contraindre le modèle à représenter chaque signal de manière équitable, il aurait fallu créer quatre autoencodeurs, chacun traitant individuellement un signal 1D. Cependant, l'optimisation et l'implémentation de cette solution n'étant pas envisageable, nous avons opté pour une alternative innovante : forcer un autoencodeur unique à représenter chaque axe indépendamment en séparant l'encodeur et le décodeur par branche (**figure 27**).




figure 27 : comparaison entre un modèle de base et notre modèle multiview
(référence : Yacouba Kaloga et al., 2021 [26])

Notre solution suggère ainsi que si l'encodeur et le décodeur se séparent comme suit la **figure 27**, les poids et les biais inscrits dans chaque neurone seront individuellement optimisés par branche durant l'entraînement. En somme, chaque branche (n) agit comme un autoencodeur indépendant ce qui élimine le problème lié aux données multivariées.

Cependant, la concaténation des vecteurs latent reste nécessaire pour garder un espace latent commun, ce qui nous permet finalement d'étudier plus précisément la distance Mahalanobis ! Le résultat de cette méthode démontre bien une reconstruction homogène peu importe le signal (**figure 28**).




figure 28: Résultat de la reconstruction d'un autoencodeur multi-branche sur les données multivariés

Dans le cas d'un autoencodeur classique, où l'espace latent est un vecteur d'informations comprimées, l'analyse de ce vecteur est compliquée, voire impossible, car la généralisation et l'étude d'une distance de Mahalanobis ou cosinus reposent sur des notions de probabilités et de statistiques. C'est pourquoi un VAE (*Variational Autoencoder* : **voir figure 19**) est nécessaire. De cette façon, nous pouvons définir à travers des tests le seuil approprié pour définir une anomalie (**figure 29**).

- > **Avantages d'un VAE:** Capacité à généraliser facilement les données de l'entraînement.
- > **Désavantages d'un VAE:** Beaucoup plus complexe à entraîner car il requiert plus de données, plus d'entraînement et plus complexe à mettre en place. De plus, il est notamment difficile à optimiser car le nombre d'hyper paramètre à régler a augmenté.

2.1.2 Entraînement

La phase d'entraînement d'un autoencodeur est simple. Toutefois, pour la simplicité du rapport, une figure a été mise en place (**annexe figure 1**) pour expliquer brièvement les différentes étapes lors de l'entraînement et l'optimisation (*training*, *validation*, *test*). Cette figure servira de référence pour toutes les architectures de type "reconstruction" qu'il s'agisse de *timeseries* ou de données 2D.

2.1.3 Résultats

Le calcul du seuil définissant un fonctionnement sain d'un fonctionnement anomalie est défini en représentant l'espace latent sous la forme d'un histogramme. De cette manière, un indice de confiance peut être émis (**figure 29**).




figure 29 : placement du seuil statique

Sachant que nous voulons un indice de confiance à 95 %, nous définissons ainsi le seuil à 95 % de la plage de score soit ~2.1.

Comme nous l'observons sur la **figure 30, ci-dessous**, nous obtenons bien une distinction entre les labels : sain et défaut.




figure 30 : observation du seuil sur la totalité des données




figure 31 : matrice de confusion sur le diagnostic de l'autoencodeur (VAE multiview)

En effectuant ainsi la détection d'anomalie vibratoire, nous pouvons finalement créer notre matrice de confusion (**figure 31**). La précision de notre modèle atteint donc 94.12 %. Toutefois, nous avons décidé de ne pas continuer sur cette méthode car elle est jugée naïve et ne fonctionnerait pas en application réelle.

2.2 Classificateur : fusion des données time-series

Suite à la mise en place et à la preuve de concept de notre VAE, la question de l'optimisation de la machine s'est posée. Un autoencodeur peut-il recommander ou optimiser une machine selon son diagnostic ? La réponse est non : il ne peut que signaler un fonctionnement normal ou anormal.

Cependant, comme évoqué dans l'introduction, la normalité n'est pas le problème. Lorsqu'un VAE détecte une déviation anormale, il est probable qu'un réglage différent mais toujours optimal ait été effectué.

Ainsi, la prochaine étape consiste à classer le comportement des différents couples d'axes en plusieurs catégories. L'approche est évidente : un classificateur ! Cette approche permettrait non seulement de recommander un réglage à l'opérateur, mais aussi, à l'avenir, de généraliser le modèle à toutes les machines et à tous les papiers.

2.2.1 Méthode

Par définition, une couche convolutionnelle extrait et restitue davantage d'informations que les couches classiques (*Dense*, *RNN*, *Linear*). Ainsi, il est naturel de privilégier cette architecture lorsque les signaux de couple moteur sont à la fois rapides et riches en informations :

- 4 ms de temps d'échantillonnage
- 6 axes de couple moteur
- 50 échantillons par fenêtre
- équivaut à 300 données

Cependant, outre les CNN 1D, les couches convolutionnelles 2D nécessitent des données bidimensionnelles, comme leur nom l'indique (CNN défini dans l'**annexe définition 9**).

Par concaténation de multiple donnée *timeseries* 1D, nous arrivons ainsi à obtenir une matrice 2D nous permettant d'exploiter ces couches convolutionnelles 2D (**figure 32, ci-dessous**).




figure 32 : explication du preprocessing employé pour le classificateur

Le fenêtrage des données contribue à faire converger le modèle vers une solution robuste en incluant ni trop d'informations, ni trop peu. Cela garantit une IA efficace, légère et généraliste. Notre contexte est particulièrement sensible à ce paramètre. Pour des séries temporelles unidimensionnelles, la longueur de la fenêtre a moins d'impact que pour des données structurées en images.

Ainsi, s'assurer que les fenêtres couvrent toujours la même localisation temporelle est crucial, car cela permet de capturer l'événement clé.

1er prototype

La première itération consiste à détecter, par algorithme, le pic de couple sur un axe moteur donné, puis à centrer la fenêtre sur cet instant. Cependant, un couple généré légèrement avant l'événement principal est aussi porteur d'information. Par exemple, si un couple apparaît un peu avant la formation du sac, la fenêtre va se centrer sur cet accoup ce qui élimine l'information que l'accoup se trouve en avance dans le temps. La notion de temporalité a donc été perdue !




figure 33 : algorithme de détection de pic, notion de temporalité n'est plus respectée

2nd prototype

La seconde itération exploite la position de l'axe de maintien pour déterminer où placer la fenêtre. En effet, il est possible d'identifier le moment exact de la formation du sac grâce à la position angulaire de l'axe de maintien et au format du sac produit. Grâce à cette méthode, nous préservons la temporalité des accoups tout en conservant un prétraitement robuste, quel que soit le profil des signaux.

Néanmoins, puisque nous ne détectons plus les pics par algorithme interne mais grâce à un signal externe, nous devons définir davantage de paramètres pour extraire correctement la fenêtre pertinente, complexifiant le *preprocessing*.

2.2.2 Entraînement

Comme pour l'entraînement de notre VAE dans la partie précédente (**Chap V.2.1**), celle du modèle classificateur agit dans la même parallélité. Seul un label est extrait pour aider et indiquer à l'IA la classe à prédire.

Un schéma simplifié suivant les différentes phases (entraînement, validation, optimisation et test) est présent dans l'**annexe figure 2**.

Remarques : Contrairement aux modèles semi-supervisés, les classificateurs supervisés traitent plusieurs classes lors de l'entraînement. De ce fait, les résultats et les données présentent la particularité de ne plus se limiter à « sain » ou « défectueux », mais à plusieurs catégories de prédiction.

Pour l'entraînement de ce modèle, une campagne de mesure a été réalisée lors de la preuve de concept, où une anomalie a été créée volontairement avec différents degrés d'impact : défaut léger, moyen, sévère et extrême. Le but de ce modèle est donc de classer suivant ces niveaux d'anomalie.

2.2.3 Résultats

Durant la phase d'entraînement, plusieurs itérations ont été menées pour optimiser le diagnostic de notre modèle. En seulement dix epochs, l'IA a atteint une précision de 100 % (voir **figure 34**).

Cependant, des doutes concernant l'overfitting ont été soulevés en raison de la convergence rapide du modèle. Pour ceci, diverses opérations ont été orchestrées pour tenter de défier les performances de l'IA :

- ajout de bruit gaussien
- shift temporel
- augmentation et diminution de l'amplitude

Au travers de ces essais, nous avons constaté non seulement que le modèle maintient une précision de 100 %, mais aussi qu'il reste robuste face au bruit et aux variations mineures susceptibles de nuire à la prédiction.




figure 34 : matrice de confusion sur notre modèle CNN classificateur

3 Approches pour signaux vibratoires

Suite à de nombreux essais, nous pouvons admettre qu'utiliser les images pour les données *timeseries* révèlent des composantes autrement difficiles à l'IA à détecter. Nous nous concentrons ainsi sur l'application d'image comme le scalogramme et le spectrogramme pour l'analyse vibratoire.

3.1 Autoencodeur : images scalogrammes

Pour étudier plus en détail le scalogramme, il convient d'en comprendre les intérêts et l'usage en traitement du signal. Un scalogramme est la représentation temps-fréquence d'un signal obtenue par transformée en ondelettes continues. On l'utilise pour les signaux transitoires et non stationnaires car, contrairement aux spectrogrammes classiques que nous avons déjà exploités, il offre une résolution adaptative en fréquence : les hautes fréquences sont localisées avec précision dans le temps, et les basses fréquences sont captées sur des fenêtres temporelles plus larges.

Dans notre cas d'usage, les anomalies machine sont masquées par des impulsions brèves lors de l'arrache du papier. Le scalogramme permet de mettre en évidence ces événements fugitifs, autrement difficiles à repérer avec d'autres méthodes (**figure ci-dessous**). C'est pourquoi son exploitation est particulièrement pertinente pour notre étude.




figure 35 : observation de la différence perceptible spectrogramme et scalogramme entre une vibration réglage bon et défaut

Remarques : Le scalogramme est un domaine très étroit et spécifique aux traitements de signal. A l'heure de l'écriture du rapport, peu de recherches ont été menées dessus comparé aux études apportées sur le spectrogramme.

Cependant, il est intéressant de voir qu'une étude sur la FFT peut être apportée car des différences d'amplitude et de phase sont perceptibles (**figure ci-dessous**) !




figure 36 : FFT sur les signaux vibratoires, une différence d'amplitude et de fréquence sont perceptibles

3.1.1 Méthode

Afin d'exploiter au mieux les avantages du scalogramme, nous nous sommes intéressés à l'étude de l'autoencodeur. Forts de notre expérience dans ce domaine, nous avons fusionné un CAE (*Convolutional Autoencoder*) et un VAE (*Variational Autoencoder*) afin de tirer parti à la fois de la capacité de généralisation du VAE et de la perception fine des détails apportée par le CAE.

Comme pour la partie **chap V. 2.1**, une figure en annexe illustre les différentes étapes de l'entraînement (**annexe figure 1**).

Remarques : Le prétraitement et la compréhension des nombreux paramètres utilisés pour le calcul du scalogramme ont nécessité une étude approfondie du sujet. En effet, pour éviter toute perte d'informations, nous avons consacré un temps considérable à étudier les différentes formules mathématiques et à suivre des thèses et journaux scientifiques afin de ne laisser passer aucune opportunité d'optimisation.

Néanmoins, nous sommes persuadés que le scalogramme peut encore être amélioré pour mieux distinguer les détails subtils associés aux différents états de fonctionnement.




figure 37 : pipeline d'extraction de fenêtre pour calculer et afficher le scalogramme de la vibration

3.1.2 Optimisations

Comme mentionné précédemment, le scalogramme est difficile à calibrer et à paramétrer correctement. En effet, sans l'expertise d'un professionnel, nous avons passé un total de trois heures à affiner le prétraitement afin de capturer le plus de détails possible. Notre expérience confirme que ces paramètres influent considérablement sur la qualité de l'image :

- taille de la fenêtre
- méthode de normalisation
- largeur de l'ondelette
- type d'ondelette (par exemple Morlet, Mexican Hat, etc.)

Bien que nous pourrions indiquer les réglages choisis pour la figure ci-dessus, nous avons constaté que ces paramètres ne sont pas universels et doivent être adaptés à chaque signal. Par conséquent, les paramètres optimaux pour un signal vibratoire ne seront pas nécessairement valables pour un autre, rendant l'entraînement de notre IA complexe.

Ceci indique clairement que nous n'avons pas découvert toutes les techniques afin d'affiner le scalogramme. Plus d'études devraient être menées à ce sujet.

3.1.3 Résultats

L'entraînement de notre VAE a nécessité un total de vingt essais durant chacun 1h même avec l'utilisation de l'accélération GPU de notre RTX Quadro T2000. Aucun résultat satisfaisant n'a pu être extrait de ces nombreux essais :

- mauvaise reconstruction des échantillons d'entraînement
- convergence nulle
- détails mal reconstruit

Nous invitons les prochains à étudier davantage le scalogramme.

3.2 Feature extraction : images log spectres

Des modèles pré-entraînés sont disponibles à leur utilisation de manière extensive comme VGG16 et ResNet152. Ces modèles d'IA sont conçus pour classer les images d'internet à travers des concours lieux périodiquement. Les gagnants sont ensuite publiés et leur modèle, exploitable gratuitement. Les images d'internet étant extrêmement complexes, les modèles mentionnés sont donc désignés pour détecter le plus de détails possible tout en gardant une généralité pour pouvoir au mieux classer les images dans leur label respectif. Cette capacité à capturer les détails et les motifs les plus profonds nous intéresse fortement.

Explication : Les filtres de ces modèles suivent une logique redondante : les premières couches servent à détecter des motifs, des contours et des formes locales qui sont pertinents pour la détection d'anomalie dans les images log spectres ou même scalogramme. En revanche, les dernières couches servent uniquement à l'ajustement par fine-tuning pour se focaliser sur la classification des informations comprimés.

Nous pouvons prendre pour exemple, le VGG16 (**figure 38**):




figure 38 : les principes des différents couches, début vs la fin
(source : Karen Simonyan & Andrew Zisserman, 2015 [27])

explication : annexe définition 4

Remarques : Notons depuis la **figure ci-dessus**, que l'image d'entrée présente une dimension spécifique à une image internet standard : 224×224 pixels et trois canaux. Ces trois canaux représentent les plages RGB nécessaires pour visualiser toutes les couleurs de l'arc-en-ciel. Nos données doivent donc convenir à cette dimension pour exploiter au mieux le modèle utilisé.

Suite à l'échec de notre VAE à reconstruire correctement les scalogrammes (voir section **V.3.1**), nous nous sommes consacrés à la classification des données vibratoires via les log-spectrogrammes. Bien que les détails y soient moins visibles à l'œil nu, rien n'indique qu'une IA ne puisse les exploiter !

En effet, des modèles d'IA détectent des cellules cancéreuses avec une précision dépassant celle d'un chirurgien expert (**Mazellier, PhD en IA appliquée à l'imagerie**). Par analogie, l'analyse des log-spectrogrammes pourrait révéler des informations cachées.

3.2.1 Méthode

Comme expliqué précédemment, nous utilisons des modèles *OpenAccess* dans le but de classer nos images log spectres. Cependant, la question est comment. Nous pourrions effectuer un *transfer learning* pour classer les images directement dans leur label, mais avec le peu de données à disposition et notre expérience, nous savons que le modèle entrera en *overfitting* très rapidement.

Notre méthode évoque donc la suppression des dernières couches (comme indiqué dans la **figure précédente**) dans le but d'exploiter l'*embedding* comme sur la **figure ci-dessous** (explication d'un *embedding* dans l'**annexe définition 5**).




figure 39 : méthode employées pour la classification des données de vibrations

Étant donné que le vecteur d'embedding produit par le modèle pré-entraîné constitue déjà une représentation compressée et pertinente des spectrogrammes, tout prétraitement additionnel sur ces vecteurs est inutile. Fort heureusement, c'est cet aspect qui rend la mise en place de cette méthode à la fois rapide et robuste.


L'installation d'un simple KNN s'est ainsi révélée aisée, offrant non seulement de bonnes performances mais aussi une robustesse au bruit, grâce aux capacités remarquables des modèles pré-entraînés (KNN est expliqué dans l'**annexe définition 7**).

3.2.2 Optimisations


Pour garantir des performances optimales et une classification robuste, nous avons procédé dans plusieurs optimisations à plusieurs étapes :

- (a) augmenter l'apparence des détails sur le spectrogramme
- (b) tester diverses modèles
- (c) application d'une réduction de dimensionnalité sur l'embedding
- (d) optimisation des hyperparamètres sur le KNN
- (e) modification des canaux du format de l'image


(a) : Changement de couleur pour augmenter les différences perceptuelles



(a) : Application d'un filtre pour éliminer le bruit de fond



(a) : Augmentation du contraste



(b) : Tests de divers modèles pour essayer de distinguer les embeddings les mieux possibles




figure 40 : différence d'embedding entre ResNet34 (a) et VGG16 (b)

L'algorithme t-SNE révèle des relations inter-features difficilement représentables par d'autres méthodes de réduction de dimension, comme le PCA (expliqué dans l'**annexe définition 6**). De nombreux articles scientifiques l'utilisent pour illustrer visuellement la qualité d'un embedding. Nous avons donc adopté une approche similaire : plus les clusters apparaissent distincts à l'œil nu dans la projection t-SNE, plus l'embedding est discriminant selon les labels.

Observations : Sur la **figure 40 (ci-dessus)**, on constate que les clusters correspondant aux différentes classes sont beaucoup plus séparés lorsque l'embedding est extrait de ResNet34. D'autres architectures ont également été testées (VGG19, ResNet50, ResNet152, DenseNet121) afin de déterminer le modèle offrant la meilleure discrimination sur nos images.

Le ResNet34 reste le plus performant d'après ces essais.

(c) et (d) : Plusieurs études menées démontrent qu'appliquer une réduction de dimensionnalité au supplément de l'embedding peut alimenter davantage une classification robuste. En effet, nous avons eu l'opportunité de mettre en pratique cette affirmation, en utilisant une technique *grid search* ou *random search* avec une *cross validation*.

L'optimisation d'un algorithme d'IA s'appuie soit sur l'expérience acquise lors d'essais antérieurs, soit sur la recherche d'hyper paramètres via des boucles sur différentes valeurs. Nous avons implémenté un **random search** fonctionnant de la manière suivante :

1. **Définition de l'espace des hyperparamètres** (par exemple, $k \in [1, 15]$, métrique $\in \{\text{euclidienne}, \text{cosinus}\}$, learning rate $\in [10^{-5}, 10^{-1}]$)
2. **Tirages aléatoires** : à chaque itération, on échantillonne une combinaison d'hyperparamètres selon une distribution (**figure 39**)
3. **Validation croisée** : pour chaque configuration, on entraîne le modèle sur un sous-ensemble training et on évalue sa performance moyenne (F1-score) sur k-folds ($k = 5$)
4. **Enregistrement des résultats** : on stocke la configuration testée et le F1-score obtenu
5. **Répétition** : on répète ces étapes pour N itérations (par ex. $N = 50$ ou 100)




figure 41 : principe du *grid search* et *random search* pour l'optimisation d'hyperparamètres
(source image : GridSearch vs Randomized Search)

A partir de cette méthode, nous pouvons ainsi trouver la meilleure combinaison d'hyperparamètres pour notre jeu de données et notre modèle.

Remarques : Ces algorithmes d'optimisation requièrent un matériel informatique puissant pour être mise en œuvre sur des modèles plus robustes et complexes. Notre *KNN* étant très simple, l'utilisation du *random search* n'a duré que 32 minutes.

(e) : Enfin, il faut tenir compte du fait que les réseaux pré-entraînés attendent des images au format $224 \times 224 \times 3$ (224×224 pixels et 3 canaux).

Nous aurions pu conserver l'image RGB telle qu'à l'étape (a), mais après plusieurs itérations, nous avons retenu une solution plus robuste : répartir les amplitudes sur les trois canaux de manière équivalente, c'est-à-dire attribuer à chaque canal un tiers de l'amplitude maximale (**figure 42, ci-dessous**) pour ensuite les normaliser de 0 à 255.




figure 42 : séparation méthodique des canaux par tier d'amplitude

Remarques : Cette technique ne consiste pas à générer des codes couleur de 0 à 255 pour chaque pixel. En effet, en utilisant notre méthode, nous mettons en valeur les zones les plus significatives de l'image, contrairement à un simple codage colorimétrique.

Contrairement aux images d'objets où la couleur véhicule une information sémantique (chat orange, voiture rouge), dans le cas des signaux, la couleur ne représente qu'une intensité ou une valeur d'amplitude.

Nous estimons à travers nos séries d'évaluation que cette méthode est la plus adaptée à notre modèle ResNet34.

3.2.2 Résultats

Notre méthode permet ainsi d'atteindre une précision d'environ 90 %, comparée au codage RGB automatique (**figure ci-dessous**). Cependant, nous constatons que notre modèle ne parvient pas à séparer certaines étiquettes, qui apparaissent relativement proches sur la **figure 44**.




figure 43 : performance de notre modèle KNN classifiant depuis l'embedding du ResNet34




figure 44 : matrice de confusion sur notre méthode proposée (KNN sur la vibration)

Bien que les résultats soient prometteurs, la précision émise par notre méthode n'atteint pas les 95% voulus (**figure 44**). De plus, même si la preuve concept de la vibration est effectuée, sa mise en place reste quelque peu flou dû au manque de matériel disponible.

4 Approches pour signaux acoustiques

4.1 Transfer learning : fusion de 3 approches

La réussite partielle obtenue avec l'embedding d'un modèle pré-entraîné pour l'analyse vibratoire a soulevé la question d'une possible amélioration si nous disposions de plus de données. Heureusement, pour l'analyse acoustique, la campagne de mesure sonore a conclu sur un double du nombre d'échantillons comparé à la vibration !

- **vibration** : 807 Mo de données + ~40 images
- **son** : 2.1 Go de données + ~110 images

Nous estimons en effet que le volume de signaux acoustiques disponible est suffisant pour tester et évaluer un modèle pré-entraîné tel que DenseNet121, mais cette fois en *transfer learning*. Concrètement, la méthode ne consiste donc plus à extraire un embedding, mais à obtenir directement une prédiction de classe via une spécialisation et un réentraînement rapide du modèle.

4.1.1 Méthode


La spécificité des données acoustiques nous permet d'explorer un domaine plus vaste du traitement du signal. Là où l'analyse vibratoire se limite aux spectrogrammes et scalogrammes, l'audio ouvre la voie à d'autres représentations temps-fréquence, comme le **melspectrogramme** :

Explications : En quelques mots, le melspectrogramme est une variante du spectrogramme, utilisant l'échelle **mel**, qui reflète la perception de l'oreille humaine : on obtient ainsi une image temps-fréquence adaptée à notre perspective auditive.

On convertit les fréquences f en échelle **mel** m :

$$m = 2595 \times \log_{10} \left(1 + \frac{f}{100} \right)$$

Cette particularité revêt un intérêt particulier dans notre cas, puisque les experts-régisseurs se fient à l'ouïe pour évaluer la qualité du réglage d'une machine.



Les études extensives sur ce nouveau graphe a notamment piqué notre intérêt car, en lui-même, la distinction entre *label* est possible, comme nous l'observons sur la **figure ci-contre**.

En conséquence, la méthode employée met à profit les atouts de chacun des graphes utilisés jusqu'à présent : le log-spectrogramme pour son observation continue dans le temps, le melspectrogramme pour sa perspective proche de l'audition humaine, et le scalogramme, qui traite efficacement les signaux non stationnaires et transitoires, convient parfaitement à notre cas d'usage.

Ainsi, cette fois-ci, le problème lié aux canaux disparaît, car nous traitons chacun d'eux séparément à l'aide de trois images (**figure 45**).




figure 45 : fusion multimodale des images en une image de 3 canaux

L'entraînement de notre modèle se soumet donc à un entraînement typique d'un classificateur (**figure ci-dessous**). L'annexe **figure 2** illustre bien les différentes phases d'entraînement.




figure 46 : schéma de notre processus de transfer learning sur le DenseNet121 en utilisant les images multimodales

4.1.2 Résultats




figure 47 : visualisation t-SNE de l'embedding juste avant les couches de classification




figure 48 : matrice de confusion du DenseNet121 classificateur

L'utilisation de DenseNet121 s'impose : les performances d'autres modèles pré-entraînés, tels que ResNet34 et VGG16, ne se rapprochent pas de celles obtenues avec DenseNet121 en utilisant cette méthode. Tout de même, la précision reste bien en deçà de nos attentes.

Bien que les résultats présentés dans cette section ne permettent pas de valider l'exploitation des données acoustiques dans notre contexte, les avancées et les observations réalisées sur le melspectrogramme nous incitent à poursuivre une étude approfondie de cette représentation.

4.2 Few-shot learning : fine tuning supervisé

Lors du développement du projet, nous avons soulevé deux points critiques : le manque de données et la capacité de l'IA à généraliser sur des exemples qu'elle n'a jamais vus. En effet, sans *finetuning*, un modèle pré-entraîné peine à s'adapter à un domaine très différent de celui sur lequel il a été entraîné, à moins de recourir à des architectures plus sophistiquées comme les transformers (utilisés dans ChatGPT, Gemini, etc...).

Parmi les solutions avancées, le few-shot learning (FSL) a retenu notre attention. Comme détaillé dans l'état de l'art, le FSL repose sur la comparaison d'embeddings : face à une nouvelle classe (par ex. un nouveau type de défaut), le modèle calcule la similarité entre l'embedding de cet exemple et ceux d'un petit jeu de référence, sans nécessiter plusieurs centaines d'exemples étiquetés. Le modèle « apprend à apprendre », plutôt que de se contenter de mémoriser des caractéristiques précises.

En contexte industriel, le few-shot learning se révèle particulièrement adapté : lorsqu'un nouveau défaut apparaît, on peut fournir seulement quelques enregistrements (par exemple 5 à 10 melspectrogrammes de ce défaut) et le modèle doit immédiatement reconnaître d'autres occurrences similaires. Cette approche est cruciale puisque, dans notre cas, les données de défaut demeurent rares et coûteuses à collecter.

4.2.1 Méthode

Avant de pouvoir appliquer le few-shot learning (FSL), il est nécessaire de disposer d'embeddings de qualité. Jusqu'à présent, nous avons utilisé des modèles pré-entraînés pour extraire puis classifier ces embeddings. Cependant, nous avons constaté que, pour nos images de melspectrogrammes (qui diffèrent fortement des images naturelles d'*ImageNet*) un réseau comme ResNet34 n'est pas optimal.

C'est pourquoi nous présentons ici une méthode originale. L'idée consiste à classifier directement à partir de l'espace latent d'un VAE non supervisé. Concrètement, nous optimisons simultanément deux fonctions de perte :

1. Une **perte de reconstruction** pour le VAE, afin de forcer l'encodeur-décodeur à capturer fidèlement les informations spectro-temporelles.
2. Une **perte de classification** (*Dense + Linear*) appliquée à l'embedding issu de l'encodeur, pour distinguer les classes d'anomalie.

Étant donné que nous rajoutons une tête de classification après l'embedding pour classifier les données, nous obtenons ainsi un **modèle hybride** structuré en deux phases :

- unsupervised pre-training
- supervised fine-tuning

Notre modèle à double entraînement figure est schématisée en deux blocs (**figure 49**). Le détail des couches utilisées dans notre VAE est en **annexe figure 13**.




figure 49 : représentation schématique de notre modèle à double entraînement

4.2.2 Résultats

L'implémentation de ce modèle a été réalisée lors de la seconde période de campagne de mesure. Le jeu de données disponible comporte 20 étiquettes (détaillées en **annexe**).

À partir de ces 20 labels, nous appliquons une *cross validation* en séparant d'abord le jeu d'entraînement et le jeu de test selon un ratio 80/20. Nous réservons ensuite une partie du jeu d'entraînement pour la validation : sur ce sous-ensemble, nous extrayons les embeddings afin d'observer la formation de clusters distincts (**figure 50**).

Remarque : Avec vingt classes, il est essentiel d'homogénéiser le nombre d'échantillons dans les ensembles d'entraînement, de validation et de test pour éviter tout biais dans la prédiction de l'IA. En effet, notre architecture (VAE) est particulièrement sensible à ce déséquilibre.

PHASE 1 - ENTRAÎNEMENT NON SUPERVISÉ




figure 50 : représentation t-SNE de l'embedding après l'entraînement n°1

Observation : Bien que la distinction globale entre les labels soit nette, quatre clusters restent très proches, ce qui suscite des interrogations. En examinant les étiquettes associées, on constate que ces clusters correspondent à des situations symétriques :

- **Group A :** avance sur la position de l'arrache et retard sur la position du maintien
- **Group B :** avance sur la position du maintien et retard sur la position de l'arrache

Remarques : Il est extrêmement important de savoir que t-SNE nécessite en lui-même des combinaisons spécifiques de paramètres pour pouvoir visualiser au mieux les jeux de données. Si l'algorithme n'est pas bien paramétré, nous risquons une mauvaise représentation des données, qui pourrait à première vue fausser notre jugement initial (**figure 51**).




figure 51 : exemple d'un t-SNE mal configuré avec perplexité = 80

Remarques : Une définition courte de la perplexité est définie dans l'**annexe définition 8**.

PHASE 2 - FINE-TUNING SUPERVISÉ

Durant cette étape, les poids du VAE vont être entièrement gelés pour pouvoir rajouter plusieurs couches de classification en sortie de l'embedding. Cette approche permet de ne pas modifier notre autoencodeur, que nous estimons comme assez discriminant pour pouvoir séparer les clusters et ainsi, uniquement modifier les neurones des nouvelles couches ajoutées !

Comme notre objectif est d'implémenter un few-shot learning (FSL), nous devons déployer le modèle pour générer des jeux de données spécifiques : *support*, *query* et *training*.




figure 52 : matrice de confusion sur le diagnostic de notre VAE avec la tête de classification, méthode FSL

Rappel : les labels sont écrits dans l'annexe table 2.

Même si la plupart des labels sont correctement prédits, une petite proportion l'est encore de manière erronée.

Remarque : Contrairement à la détection d'anomalies, où des défauts différents peuvent parfois produire des signatures très similaires (par exemple, un outil dont une dent est fortement endommagée peut avoir une signature proche de celle d'un outil légèrement usé), chaque réglage d'optimisation de machine demeure, par nature, indépendant. Autrement dit, dans le cadre de l'optimisation, on s'attend à ce que chaque paramètre modifie le comportement de la machine de façon suffisamment distincte pour être traité comme un label séparé.

Hypothèse : il est toutefois possible que certains réglages présentent un impact très voisin sur la machine ou le moteur, ce qui expliquerait que le modèle, malgré la présence d’une diagonale prédite (TP), confonde parfois deux réglages aux effets voisins (**figure 52**).

5 Synthèse des modèles d’IA

Liste exhaustive de tous les modèles explorés ci-dessous.

Précision : Définition et formule dans l’**annexe définition 10**.

Modèles	Donnée	Précision	Type	Difficulté	Robustesse	Poid du modèle
RNN	SIMO (timeseries)	82.3 %	classificateur	★	★	30 ko
AE	SIMO (features)	mauvais	reconstruction	★★	★	102 ko
AE	SIMO (timeseries)	mauvais	reconstruction	★	★	124 ko
LSTM	SIMO (timeseries)	mauvais	prévision	★	★	78 ko
AE - multiview	SIMO (timeseries)	89.12 %	reconstruction	★★★★	★★	203 Mo
TF - VGG16	SIMO (image)	86.2 %	classificateur, transfer learning	★★★★	★★	528 Mo
VAE + FSL	SIMO (image)	87.0 %	reconstruction, few-shot learning	★★★★★	★★★★	328 Mo + 20 ko
CNN 2D	SIMO (timeseries)	100 %	classificateur	★★★★	★★★★	54 ko
Kmeans	VIB (timeseries)	mauvais	clustering	★	★	--
FFT analysis	VIB (fréquentiel)	à analyser	statistique	★	-	--
CAE - logspectre	VIB (image)	mauvais	reconstruction	★★★★	★★★★	128 Mo

CAE - scalogramme	VIB (image)	?	reconstruction	★★★★★	★★★	128 Mo
VGG16 - feature extraction	VIB (image)	89.42 %	classificateur	★★★	★★	528 Mo
FFT analysis	SON (fréquentiel)	à analyser	statistique	★	-	--
Kmeans	SON (timeseries)	mauvais	clustering	★	★	--
CAE - logspectre	SON (image)	mauvais	reconstruction	★★★	★★	128 Mo
VAE - logspectre	SON (image)	mauvais	reconstruction	★★★★★	★★★★	258 Mo
VAE - scalogramme	SON (image)	mauvais	reconstruction	★★★★★★	★★★★	258 Mo
VGGish - KNN	SON (timeseries)	71.3 %	feature extraction, classificateur	★★★	★★	290 Mo
TF - DenseNet121	SON (image)	74.75 %	classificateur	★★★	★★	30.8 Mo
VAE + FSL - melspectrogramme	SON (image)	83.5 %	reconstruction, few-shot learning	★★★★★★	★★★★★ ★	302 Mo + 18 Ko

Chapitre VI : Phase d'implémentation

Depuis plusieurs mois, HolwegWeber développe un projet d'industrialisation reposant sur un *Edge Gateway*, capable de relier à distance les automates internes des machines client à un réseau externe. Ce dispositif embarqué exploite des protocoles Industry 4.0 tels que l'OPC UA pour remonter en temps réel des données vers le client et le service après-vente.

Notre stage intervient au cœur de cette démarche : nous visons l'intégration de nos modèles d'IA dans un système *Edge* industriel, à savoir le boîtier Belden Hirschmann OpEdge 8D.

Ce chapitre détaille la démarche suivie pour déployer nos algorithmes au sein de cet environnement embarqué, en utilisant les outils et architectures logicielles adaptés.

1 Pipeline globale




figure 53 : schéma de notre processus de communication

Le but de notre implémentation est d'établir une connexion directe entre une IA et l'automate sans devoir passer par un ordinateur personnel. La solution ici, est d'utiliser le boîtier Belden Hirschmann OpEdge 8D, que nous appellerons le boîtier *Belden* dès à présent.

Nous devons ainsi établir plusieurs choses afin de mettre en place la pipeline voulue (**figure 53**) :

- **Activer OPC UA** server du côté automate et OPC UA client du côté boîtier Belden
- Trouver un moyen de **déployer notre modèle** d'IA
- **Communiquer** chaque processus harmonieusement

En résumant, nous voulons une communication Automate → Belden → IA → Automate.

1.1 Architecture d'acquisition et intégration

Cette première étape consiste à implémenter le programme nécessaire à l'acquisition des données et l'exposition des variables en temps réel via OPC UA server. Nous détaillons ainsi :

- les **modifications du programme** existant dans *Simotion*
- la création d'une **tâche *ServoSynchronousTask*** afin d'assurer une fréquence d'échantillonnage constante
- l'ajout d'une **interface ergonomique**
- l'**exposition de variables** sur OPC UA server à travers *Simotion* webservice

1.1.1 Modification du programme

La cadence de la machine influe directement sur la résolution temporelle des données issues de l'automate Simotion (250 Hz). À haute vitesse, chaque cycle est plus rapide et le pas d'échantillonnage devient proportionnellement plus grossier, ce qui dégrade la finesse de mesure. En revanche, à basse cadence, on bénéficie d'une meilleure résolution, facilitant l'analyse fine des réglages optimaux évoqués au **chapitre III**.

Pour garantir une acquisition stable et limiter les micro-variations, nous avons choisi de forcer la machine à tourner à une vitesse prédéfinie. L'affichage de la cadence sur l'IHM utilise un type *REAL*, donc à virgule flottante, ce qui peut induire un léger écart par rapport à la valeur affichée qui est un *INT*, nombre entier. Afin d'assurer une vitesse constante — ici fixée à 30 sacs/min — nous avons modifié le code *FC_Gen* : l'appui sur un bouton règle la machine automatiquement à la cadence désirée (**annexe figure 3**).

Remarques : Nous privilégions l'unité « sacs par minute » plutôt que « mètres par minute » car notre analyse porte sur les accoups générés à chaque production de sac, indépendamment de sa longueur (200 mm ou 400 mm). Ainsi, la variation de format n'affecte pas la constance du cycle de production, nous permettant d'avoir un accoup prévisible dans le temps.

1.1.2 Tâche *ServoSynchronousTask*

Cependant, déclarer simplement notre bloc ST ne suffit pas à le faire s'exécuter à la fréquence de 4 ms du SIMO. Par défaut, il est enregistré comme tâche de fond (*Background Task*), donc rafraîchi à une cadence réduite.

Pour garantir la réception et l'enregistrement immédiat des données, nous devons donner la plus haute priorité à notre programme. Nous l'avons donc converti en *PROGRAM* et associé à une *ServoSynchronousTask* (**figure 54**), assurant ainsi son exécution à chaque cycle de 4 ms et le remplissage de la table (**figure 55**).




figure 54 : insertion du programme ST créé dans une tâche d'exécution rapide, ServoSynchronousTask

```

IF VIH_bSwitch_1 AND bConscadStable AND NOT bDataReady THEN
  IF iSampleIndex <= 300 THEN

    aTorqueAppE[iSampleIndex] := LREAL_TO_REAL(_to.Axe_AppE.actualTorque.value); // Récupération données par couple
    aTorqueAppS[iSampleIndex] := LREAL_TO_REAL(_to.Axe_AppS.actualTorque.value);
    aTorqueArra[iSampleIndex] := LREAL_TO_REAL(_to.Axe_Arra.actualTorque.value);
    aTorqueMain[iSampleIndex] := LREAL_TO_REAL(_to.Axe_Main.actualTorque.value);
    aTorqueIF[iSampleIndex] := LREAL_TO_REAL(_to.Axe_IF.actualTorque.value);
    aTorquePerf[iSampleIndex] := LREAL_TO_REAL(_to.Axe_Perfo.actualTorque.value);
    timeDTArray[iSampleIndex] := dtTpsCPU_n; // Vérification du temps cycle code (au cas où c'est pas 4 ms)

    iSampleIndex := iSampleIndex + 1; // Incrément pour remplir le tableau

    bAcquisitionInProgress := TRUE;
  END_IF;
END_IF;

```

figure 55 : démonstration d'un bout du code FC_Test afin de remplir la table

Remarques : *Simotion Scout v5.6* ne dispose pas d'une structure capable de stocker des données en 2 dimensions, nécessitant ainsi la création d'une table unique à une dimension pour chaque variable.

1.1.3 Interface ergonomique

Afin de pouvoir contrôler et surveiller le processus en cours, nous devons créer une interface ergonomique. L'interface doit remplir plusieurs critères : création d'un bouton sur l'IHM afin de mettre la machine à cadence voulue, indication pour montrer dans quel étape nous sommes (acquisition, diagnostic, entraînement), ainsi qu'une table montrant les états de la machine (dysfonctionnement, interruption, problème technique : comme erreur de connection ou autre). Les captures d'écrans sont dans l'annexe figure 4.

1.1.4 Mise en place de l'OPC UA

Les automates *Simotion* disposent d'un webserver pour configurer l'export des variables. C'est à travers cette interface que nous exposons les variables voulues (figure 56). Néanmoins, l'automate doit premièrement être configuré correctement de façon à exporter les variables du bon automate (annexe figure 5).




figure 56 : Exposition des bonnes variables en sélectionnant le programme ST, FC_Test

Avec ces étapes finies, nous pouvons ainsi assurer que les variables souhaités sont correctement affichées depuis l'OPC UA Server. Nous devons désormais passer à la configuration du boîtier Belden afin de réceptionner les données depuis l'OPC UA Client.

1.2 Edge Gateway

Le boîtier Belden Hirschmann OpEdge 8D assure la réception des données OPC UA et la communication vers l'IA. Toutefois, une configuration du boîtier Belden n'est pas nécessaire car toutes les fonctions sont présentes dans *nodeRED*. En effet, l'intégration de *nodeRED* au sein même du gateway facilite l'implémentation de notre IA (figure 57). Il est important de noter que la configuration du boîtier passe par deux sites internet locaux : **Belden Hirschmann Local Configuration** et **BHDO** (ou **Belden Hirschmann Data Operations**). Le premier sert à la configuration interne, comme pour l'ajout d'un conteneur (que nous utiliserons plus tard). Le second sera dûment exploité pour connecter le boîtier aux automates.




figure 57 : accès au flow definition, ou nodeRED du boîtier Belden

Ainsi, à travers cette interface utilisateur simple et efficace, nous pouvons configurer des nœuds sur *nodeRED* afin d'implanter la communication OPC UA (annexe figure 7).

La communication OPC UA → Belden a bien été implémentée. Un exemple de donnée réceptionné est en annexe figure 8.

1.3 Déploiement IA

Cette section détaille la mise en production de notre modèle de détection d'anomalie dans le boîtier Belden, suivant quatres étapes clés :

- Création du **conteneur Docker**
- **Implantation** dans le boîtier Belden
- Mise en place d'une **communication API**

1.3.1 Création du conteneur Docker

Notre modèle repose sur des bibliothèques Python spécialisées (*PyTorch*, *TensorFlow*, *SciPy*, etc.), qui exigent un système d'exploitation compatible avec Python 3.10 et ses dépendances. Or, bien que le boîtier Belden intègre un OS industriel, son accès bas niveau et son environnement ne permettent pas d'installer et d'exécuter directement un script Python sophistiqué : ces opérations sont réservées aux ingénieurs du fabricant.

Pour pallier cette contrainte, nous utilisons Docker. Un conteneur Docker encapsule l'ensemble des dépendances (version de Python, bibliothèques, scripts) et s'exécute en isolation, comme une machine virtuelle légère (**figure 58**). Cette solution garantit que notre IA fonctionne de façon identique sur un PC de développement et sur le boîtier Belden, sans modifier son OS natif ni requérir de privilèges système dont nous disposons pas.




figure 58 : schéma par couche de la technologie d'un conteneur
(source : Rekha Gangula et al., 2023 [22])

Ainsi, notre conteneur consomme non seulement très peu de ressource car il est optimisé à n'avoir besoin que du minimum pour le faire tourner, mais il est aussi sécurisé et léger. En effet, chaque conteneur a sa propre librairie et son point d'accès personnel garantissant que le script n'accède pas à un autre niveau du Host OS (**annexe figure 9**).

Chap VI. 1. Pipeline globale

Comme mentionné dans la partie précédente, **chap VI. 1.1**, nous avons plusieurs conteneurs à créer :

- **diagnostic** : conteneur IA qui utilise un modèle (.pth) à disposition pour récupérer les données OPC UA et ressortir une prédiction
- **entraînement** : conteneur IA qui utilise les fichiers (.h5 — définition dans l'**annexe définition 1**) stockés pour entraîner notre modèle. Il est nécessaire de l'utiliser dans le cas où nous n'avons pas un modèle (.pth) à disposition au préalable.
- **sauvegarde** : conteneur permettant de convertir les données OPC UA depuis *nodeRED* en fichier .h5 à stocker dans un volume

Nous sommes ainsi inscrits dans un problème *multi-container* où chaque conteneur doit interagir entre eux pour accéder au même volume (volume : défini dans l'**annexe définition 2**).

En effet, dans notre cas, nous avons besoin d'un volume pour stocker les données (.h5) ainsi que les poids du modèle (.pth) comme suit (**figure 59**).




figure 59 : démonstration du contenu de notre volume ai-project-docker_model_data à travers le logiciel Docker Desktop

Pour que le conteneur puisse accéder au volume, nous devons donner un ordre. Néanmoins, comme mentionné précédemment, un conteneur est isolé du reste de l'OS. Nous devons ainsi utiliser un RESTful API pour exposer le point d'accès comme figuré sur l'**annexe figure 9** (ex : Image2/app avec Image2 le nom du conteneur et /app, le point d'accès).

1.3.2 Communication API

Sur la **figure ci-dessous**, nous avons mis en évidence le port HTTP RESTful API des différents conteneurs ainsi que leur point d'accès. Ces ports seront utilisés et appelés dans des nœud HTTP *nodeRED* pour donner un ordre, demander une requête ou injecter des données : ils sont utilisés dans les blocs **(d)**, **(e)**, **(g)** et **(h)** de l'**annexe figure 6.e**.




figure 60 : exposition des point d'accès ainsi que leur port HTTP pour la communication

Une fois que le prototype est fonctionnel sur le PC de développement, il suffit d'exporter le conteneur en image (.tar) et de l'injecter dans l'onglet correspondant au boîtier Belden.

1.3.3 Implantation dans le boîtier Belden

L'implémentation au sein du boîtier Belden est simple et rapide. Le manuel guide d'utilisation "Hirschmann OpEdge 8D" explique clairement les étapes à suivre ainsi que les ajouts nécessaires pour déployer le volume ainsi que les conteneurs dans le port voulu. Des preuves du déploiement sont disponibles dans l'**annexe figure 11**.

Remarques : Il est important de souligner que certains ports ne doivent pas être utilisés. Pour rappel, ces ports sont mis en **annexe figure 10**.

2 Résultats

Bien que le déploiement total de notre solution fut un succès, le manque de disponibilité machine ainsi que de temps a restreint nos essais par un test unique d'un seul label. Cependant, le modèle a tout de même diagnostiqué la machine correctement par rapport à l'entraînement qu'il a subi (**figure 61, ci-dessous** et **annexe figure 4.c**).

```
26/05/2025 17:13:15 node: diagnosis DEBUG
msg: Object
  object
    payload: object
      avg_probabilities: array[1]
        0: 1
      top3: array[1]
        0: object
          confidence: 1
          id: 0
      _msgid: "0ef3638cffc0b44e"
    statusCode: 200
```

Label prédit : ID 0 soit "réglage optimal"
Avec certitude de 100 %

figure 61 : résultat du diagnostic sur un noeud debug de *nodeRED*

Nous avons notamment pu effectuer un entraînement de notre IA purement à travers l'IHM ce qui signifie que la sauvegarde des données (.h5), l'entraînement, ainsi que l'export du modèle (.pth) fut aussi un succès (**figure 62, ci-dessous**).

```
26/05/2025 17:12:38 node: debug 17
ns=2;s=unit/FC_Test.VIHM_bTrainAI : msg.payload: Object
  object
    msg: "training successful at allround=1.500; early-stopped at epoch 6; copied .h5 to database/"
    status: "ok"

26/05/2025 14:59:50 node: debug 16
msg.payload: Object
  object
    path: "/app/model_data/training/label_0_1748264390.h5"
    status: "saved"

26/05/2025 15:00:25 node: cleanup DEBUG
ns=2;s=unit/FC_Test.VIHM_bCleanupDB : msg.payload: Object
  object
    deleted_files: 4
    status: "ok"

label_0_1748272240.h5 label_0_1748272255.h5
# cd ..
# ls
CNN_v1.pth training
```

figure 62 : résultat de l'entraînement, suppression et sauvegarde des données sur plusieurs noeuds debug de *nodeRED*. L'affichage du contenu du volume démontre aussi la présence des fichiers correspondants (**capture d'écran pris à un autre moment, d'où la différence du nombre et noms des fichiers .h5**). Le terminal provient du Shell d'un des conteneurs.

3 Remarques

Comme évoqué dans le **chapitre III**, un modèle IA entraîné sur une seule machine et un seul type de papier ne va pas réussir à se généraliser à d'autres machines et autres papiers. Pour remédier à cela, nous avons intégré la possibilité de ré-entraîner le modèle directement sur site, sans passer par un PC externe. Ce réentraînement embarqué, lancé via plusieurs boutons sur l'IHM, a permis de montrer que le boîtier est en mesure de fournir un modèle adapté à une nouvelle machine et un nouveau papier. En revanche, il ne sera pas plus général, mais simplement respecialisé au nouveau jeu de données.

De plus, afin de garder une traçabilité et de la persistance sur les données de ces sessions, nous avons monté en volume un stockage Docker dédié (**chap VI. 1.3**). Toutes les traces et les versions du modèle entraîné y seront stockées et cela ouvrira, à terme, la possibilité de faire des études sur les variations des signaux suivant le temps et l'environnement.

Enfin, par manque de temps, nous n'avons pas pu mener une série exhaustive de tests en conditions réelles pour valider un maximum de cas. Cette validation sur le terrain reste donc à faire afin de s'assurer de la pertinence de la solution sur une large gamme de formats et de machines différents.

Chapitre VII : Résumé global

Ce chapitre a pour objectif de récapituler brièvement les différentes étapes menées tout au long du projet. Il se divise en deux grandes parties : la recherche exploratoire et l'implémentation pratique.

1 Partie recherche

Durant la phase de recherche exploratoire, l'accent a été mis sur la sélection et l'analyse des signaux discriminants (couple moteur, vibrations et acoustique). Des approches variées ont été testées pour traiter ces signaux, notamment l'utilisation d'autoencodeurs multiview, la classification à partir de séries temporelles, et l'analyse spectrale à travers des scalogrammes et des log-spectres. Ces expérimentations ont démontré que les modèles d'intelligence artificielle choisis permettaient effectivement de détecter les anomalies avec une grande précision et fiabilité, en particulier grâce à une optimisation fine des prétraitements et à l'étude poussée des espaces latents.

2 Partie implémentation

La phase d'implémentation a permis de concrétiser les résultats obtenus lors de la phase exploratoire en déployant la solution sur une architecture industrielle réelle. Il est important de marquer que le modèle utilisé (CNN 2D, voir **chap V. 5**) n'utilise que les données du couple car aucun capteur supplémentaire n'a été mis en place. Une attention particulière a été accordée à l'intégration robuste du modèle d'IA au sein de l'environnement *Simotion* et à la mise en place efficace de la communication OPC UA. Les résultats pratiques démontrent que le système est capable de détecter en temps réel les situations menant à des casses-papier, facilitant ainsi le travail des régleurs tout en réduisant significativement les pertes matérielles.

Chapitre VIII : Conclusion et perspectives

Conclusion générale

La formation du boyau demeure un processus complexe, nécessitant l'expertise d'un régleur afin de le régler au mieux. À travers notre projet, nous avons étudié l'intérêt que portent différents signaux comme la vibration, le son et le couple moteur sur le comportement de la machine suivant les défauts et jeux de réglage. En effet, la complexité des signaux nécessite une analyse profonde, souvent montrant une complexité difficilement visible à l'œil humain. Cette complexité rend l'analyse des signaux par intelligence artificielle quasiment obligatoire et tout à fait pertinente. Ainsi, nous avons démontré à travers multitude de tests et d'essais que l'analyse par IA est possible. En effet, nous avons eu l'occasion de tester diverses méthodes de preprocessing allant de la concaténation simple, à la conversion des signaux temporels en image scalogramme. Grâce à ces approches rigoureuses et méthodiques, nos modèles ont permis de diagnostiquer en simulation divers signaux issus de la RS26 avec une précision de plus de 80 %, montrant encore une fois, un intérêt fort à l'application d'IA dans notre projet.

De plus, une solution prometteuse quant à l'implémentation de notre modèle en système embarqué est proposée. Par ailleurs, en collaboration avec Belden Hirschmann, nous pensons que notre application pourrait avoir un impact positif sur la durée de réglage d'une machine complexe comme la RS26, économisant à la fois du temps mais aussi permettant de diminuer la charge des tâches manuelles sur les régleurs. À terme, cette solution contribuera à diminuer la casse-papier et les pertes associées, tant économiques qu'environnementales.

Cette intégration contribue significativement à la transition industrielle vers l'industrie 5.0, permettant à Holweg de renforcer son leadership dans la fabrication de sacs écoresponsables.

En raison de la disponibilité limitée des machines pour les essais, nous n'avons pu déployer qu'un prototype de test ; il n'a pas été possible de consolider une solution véritablement robuste. Par conséquent, notre travail s'est arrêté à la phase expérimentale, sans planifier un déploiement à long terme.

Perspectives et travaux restants

De nombreux axes de travail sont envisageables pour améliorer la robustesse et la capacité de notre solution à être utilisée sur de nombreuses machines. Tout d'abord, il sera très utile d'enrichir le jeu de données à disposition : en collectant des signaux sur un grand nombre de machines RS26, de formats et de types de papier, le modèle pourra apprendre sur des variations plus riches. Cela impliquera probablement de complexifier le modèle mais permettra une meilleure généralisation.

Ensuite, il sera intéressant de délimiter précisément l'intervalle de réglage possible pour une même machine. Pour cela, il faudrait parcourir toutes les combinaisons de paramètres du boyau pour délimiter la zone acceptable puis identifier précisément le point où les réglages commencent à sortir des tolérances. Cette méthode serait intéressante et fournirait à l'opérateur ainsi qu'à nous une véritable indication sur la qualité d'un réglage machine.

Enfin, d'un point de vue méthodologique, il serait intéressant d'explorer l'apprentissage par renforcement en automatisant le boyau avec des capteurs et actionneurs. L'IA pourrait essayer différentes configurations et selon un système de récompense, convergerait ensuite vers un réglage optimal sans supervision. Si une telle infrastructure n'est pas encore accessible, il est possible d'implémenter un modèle auto-labellisé : le modèle s'aiderait des caractéristiques visuelle des sacs pour générer lui-même des labels, puis s'adapte au fur et à mesure de l'arrivée de nouvelles séquences de données.

De plus, l'ajout d'une ou plusieurs caméras permettraient de surveiller la ligne et de voir en temps réel si le sac est bien formé. Ces nouveaux labels pourraient ensuite être exploités pour enrichir le jeu de données d'entraînement et ainsi améliorer encore plus la qualité du modèle. La prochaine étape consistera à élargir le système vers la maintenance prédictive. En associant diverses métriques comme la détection d'anomalie couplée avec la durée de vie des machines, nous pourrions anticiper l'usure prématurée des composants comme les galets de rattrapage ou les pinces d'arrache.

Concernant l'interface, il est essentiel de finaliser et de valider avec les régleurs une interface utilisateur plus ergonomique. Cela inclut une interface plus simple, des indicateurs visuels clairs et un historique des réglages, afin de faciliter son adoption sur le terrain.

Enfin, il est crucial de porter une attention particulière à la cybersécurité. L'API RESTful utilisée pour communiquer avec l'IA pourrait représenter une vulnérabilité, il sera donc indispensable d'implémenter un moyen de sécuriser la communication.

Ces perspectives permettront à Holweg de renforcer son positionnement concurrentiel en intégrant des solutions d'IA de pointe. En adoptant ces innovations dès aujourd'hui, l'entreprise se donnera les moyens d'anticiper les évolutions du marché et de conserver un avantage durable face à la montée en puissance des technologies d'apprentissage automatique.

Bilan financier

Durant notre stage de six mois, nous avons perçu la rémunération minimale (4,35 €/h). Le premier mois a été consacré à l'intégration et à la prise en main des processus internes, puis le second mois à l'analyse IA d'un jeu de données limité, en l'absence d'accès aux machines. Le prototype opérationnel, incluant le packaging Docker et la configuration Node-RED sur boîtier Belden Hirschmann Edge, a été déployé en une semaine, sans frais matériels autres que nos charges salariales.

Sur le plan financier, notre intervention se limite à un coût salarial d'environ 3 600 €. Le boîtier Belden, acquis avant notre arrivée, n'a pas été facturé au projet, et tous les autres équipements (machines clientes, postes de travail, logiciels sous licence ou open source) étaient déjà disponibles. Nous avons ainsi réalisé l'intégration et les tests sans frais supplémentaires.

Pour envisager un déploiement industriel robuste, il conviendrait toutefois d'équiper la machine de quatre accéléromètres de vibration placés aux points critiques du boyau, ainsi que d'un IO-Link Master pour la collecte synchronisée des données haute fréquence. D'après les devis de Pepperl & Fuchs, l'IO-Link Master s'élève à 1 150 € TTC et chaque capteur de vibration à 327,94 € TTC.


Hypothétiquement, le budget matériel total TTC s'établit donc à $1150\text{€} + (4 \cdot 327.94\text{€}) = 2461.76\text{€}$. L'intégration de ces équipements supplémentaires enrichirait la qualité des données destinées au diagnostic et permettrait de couvrir l'ensemble des scénarios de réglage. En répartissant les accéléromètres à plusieurs emplacements stratégiques, il deviendrait possible de détecter les micro-variations et de localiser précisément l'origine des anomalies. Cette couverture exhaustive contribuerait à renforcer la fiabilité et la précision de notre système d'IA.

Bibliographie

- [1]. Yeqi Liu, Huihui Yu, Chuanyang Gong, Yingyi Chen, 2020. A real time expert system for anomaly detection of aerators based on computer vision and surveillance cameras, *Journal of Visual Communication and Image Representation*.
- [2]. Alessandro Baldini, Riccardo Felicetti, Francesco Ferracuti, Alessandro Freddi, Sabrina Iarlori, Andrea Monteriù, 2023. Real-time propeller fault detection for multirotor drones based on vibration data analysis. *Engineering Applications of Artificial Intelligence*.
- [3]. M.A. Zakei Harandi, Tzu-Yuan Lin, Chen Li, Sigurd L. Villumsen, Maani Ghaffari, Ole Madsen, 2025. ScaloAdaptAlert, a novel framework for supervised anomaly detection in industrial acoustic data, integrating power scalograms, adaptive filter banks, and convolutional neural networks — A case study. *Journal of Manufacturing Systems*
- [4]. Oliver, A., Odena, A., Raffel, C. A., Cubuk, E. D., & Goodfellow, I. (2018). Realistic evaluation of deep semi-supervised learning algorithms. *Advances in Neural Information Processing Systems*, 31.
- [5]. Zhou, Y., Song, X., Zhang, Y., Liu, F., Zhu, C., & Liu, L. (2022). Feature encoding with autoencoders for weakly supervised anomaly detection. *IEEE Transactions on Neural Networks and Learning Systems*, 33(6), 2454–2465.
- [6]. Su, Y., Zhao, Y., Niu, C., Liu, R., Sun, W., & Pei, D. (2019). Robust anomaly detection for multivariate time series through stochastic recurrent neural network. In *Proceedings of the 25th ACM SIGKDD international conference on knowledge discovery & data mining* (pp. 2828–2837).
- [7]. Nesryne Mejria, Laura Lopez-Fuentes, Kankana Roy, Pavel Chernakova, Enjie Ghorbel b,a , Djamila Aouadaa. (2024). Unsupervised anomaly detection in time-series: An extensive evaluation and analysis of state-of-the-art methods. *Expert Systems with Applications Volume 256*.
- [8]. Tax, D. M., & Duin, R. P. (2004). Support vector data description. *Machine Learning*, 54, 45–66.
- [9]. Kuigeng Lin, Jianing Pan, Yibo Xi, Zhenyu Wang, Jianqun Jiang. (2024). Vibration anomaly detection of wind turbine based on temporal convolutional network and support vector data description. *Engineering Structures, Volume 306*
- [10]. Marco Pota, Giuseppe De Pietro, Massimo Esposito. (2023). Real-time anomaly detection on time series of industrial furnaces: A comparison of autoencoder architectures. *Engineering Applications of Artificial Intelligence, Volume 124*.
- [11]. Yuan Mei, Yuting Wu, Li Lin. (2016). Fault diagnosis and remaining useful life estimation of aero engine using LSTM neural network. *2016 IEEE International Conference on Aircraft Utility Systems*.
- [12]. K Manjunath, Suman Tewary, Neha Khatri, Kai Cheng. (2023). Monitoring of machining process anomalies in diamond turning of Ti6Al4V alloy using transfer learning-based algorithms, *Computers & Industrial Engineering, Volume 182*.
- [13]. Ruqiang Yan, Zuogang Shang, Hong Xu, Jingchen Wen, Zhibin Zhao, Xuefeng Chen, Robert X. Gao. (2023). Wavelet transform for rotary machine fault diagnosis : 10 years revisited. *Mechanical Systems and Signal Processing, Volume 200*.
- [14]. Md Shofiqul Islam, Khondokar Fida Hasan, Hasibul Hossain Shajeeb, Humayan Kabir Rana, Md. Saifur Rahman, Md. Munirul Hasan, AKM Azad, Ibrahim Abdullah, Mohammad Ali Moni. (2025). Multimodal marvels of deep learning in medical diagnosis using image, speech, and text: A comprehensive review of COVID-19 detection. *AI Open, Volume 6*.

- [15]. Hao Huang, Zhaoli Wang, Yaoxing Liao, Weizhi Gao, Chengguang Lai, Zushu Wu, Zhaoyang Zeng. (2024). Improving the explainability of CNN-LSTM-based flood prediction with integrating SHAP technique. *Ecological Informatics*, Volume 84.
- [16]. Davide Azzalini, Benedetta Flammini, Claudio Alfredo Emanuele, Antonio Guadagno, Enrico Ragaini, Francesco Amigoni. (2025). An empirical evaluation of deep autoencoders for anomaly detection in the electricity consumption of buildings. *Energy and Buildings*, Volume 327.
- [17]. Asif Ahmed Neloy, Maxime Turgeon. (2024). A comprehensive study of auto-encoders for anomaly detection: Efficiency and trade-offs. *Machine Learning with Applications*, Volume 17.
- [18]. Muhammad Abdullah Hafeez, Adnan Ul-Hasan, Faisal Shafait. (2023) Incremental Learning of Object Detector with Limited Training Data. *Proceedings of the Digital Image Computing : Techniques and Applications (DICTA)*
- [19]. Mohammed Alduais, Qipei Mei, Amir Hosein Taherkhani, Fei han. (2025). Transfer learning on lateral capacity prediction of monopile foundations with limited data. *Computers and Geotechnics*, Volume 185.
- [20]. Lei Le, Andrew Patterson, Martha White. (2018) Supervised autoencoders: Improving generalization performance with unsupervised regularizers. *Neural Information Processing Systems*, NeurIPS conference.
- [21]. Yu Cheng, Kin Yeung Wong, Kevin Hung, Weitong Li, Zhizhong Li, Jun Zhang. (2018). Deep Nearest Class Mean Model for Incremental Odor Classification. *transactions on Instrumentation and Measurement*
- [22]. Rekha Gangula, G. Jagadeesh Kumar, Sesham Anand, A.V. Krishna Prasad. (2023). Integration of dynamic Docker containers and kubernetes with advanced cloud and Internet of Things. *Materials of Today: Proceedings*, Volume 80
- [23]. Fabio D'Urso, Corrado Santoro, Federico Fausto Santoro. (2019). Wale: A solution to share libraries in Docker containers. *Future Generation Computer Systems*, Volume 100
- [24]. Wasim Zaman, Muhammad Farooq Siddique, Shafi Ullah Khan, Jong-Myon Kim. (2025). A new dual-input CNN for multimodal fault classification using acoustic emission and vibration signals. *Engineering Failure Analysis*, Volume 179
- [25]. María Herrero-Tudela, Roberto Romero-Oraá, Roberto Hornero, Gonzalo C. Gutiérrez Tobal, María I. López, María García. (2025). An explainable deep-learning model reveals clinical clues in diabetic retinopathy through SHAP. *Biomedical Signal Processing and Control*, Volume 102
- [26]. Yacouba Kaloga, Pierre Borgnat, Sundeep Prabhakar Chepuri, Patrice Abry, Amaury Habrard. (2021). Variational graph autoencoders for multiview canonical correlation analysis. *Signal Processing*, Volume 188
- [27]. Karen Simonyan & Andrew Zisserman. (2015). Very deep convolutional networks for large-scale image recognition. *Conf ICLR 2015*
- [28]. Sebastian Bittrich, Marika Kaden, Christoph Leberecht, Florian Kaiser, Thomas Villmann, Dirk Labudde. (2019). Application of an interpretable classification model on Early Folding Residues during protein folding. *BioData Mining*, 12


Annexe

Automate	Fonction
 ET200	La sécurité est gérée par un automate de sécurité pour arrêter la machine en cas d'anomalie (par exemple : arrêt d'urgence, carter ouvert, détection d'une rupture de bande). Ces automates sont destinés à garantir l'intégrité des opérateurs et de la machine.
 TP1200 Comfort	L'IHM (<u>Interface Homme-Machine</u>) est responsable pour l'affichage de divers paramètres sur un écran tactile. Il permet donc la supervision de l'état de la machine par l'opérateur.
 SIMO D435	Le variateur (<u>ou Drive</u>) désigne l'automate d'asservissement des moteurs. Il centralise la gestion des moteurs, facilitant la communication temps-réel entre moteur et les autres automates.


annexe tableau 1 : les principaux automates présents sur les machines

Label ID	Texte
L1	Réglage normal
L2	Augmentation de la pression d'arrache (+ $\frac{1}{4}$ de tour)
L3	Augmentation de la pression d'arrache (+ $\frac{1}{2}$ de tour)
L4	Pression des galets de rattrapage est trop élevé (+ $\frac{1}{4}$ de tour)
L5	Réduction de la pression d'arrache (- $\frac{1}{4}$ de tour)
L6	Réduction de la pression d'arrache (- $\frac{1}{2}$ de tour)
L7	Augmentation de la pression de maintien (+ $\frac{1}{4}$ de tour)
L8	Augmentation de la pression de maintien (+ $\frac{1}{2}$ de tour)
L9	Réduction de la pression de maintien (- $\frac{1}{4}$ de tour)
L10	Réduction de la pression de maintien (- $\frac{1}{2}$ de tour)
L11	Réduction de la tension AppE sur IHM (-10%)
L12	Réduction de la tension AppS sur IHM (-10%)
L13	Augmentation de la tension AppE sur IHM (+10%)
L14	Augmentation de la tension AppS sur IHM (+10%)
L15	Avance sur la position de l'arrache (donc arrache trop tôt)
L16	Retard sur la position du maintien (donc maintien trop tard)
L17	Pression du galet de rattrapage
L18	Retard sur la position de l'arrache (donc arrache trop tard)
L19	Avance sur la position du maintien (donc maintien trop tôt)
L20	Position des soufflets trop serrés

annexe tableau 2 : liste des labels avec leur numéro et leur signification




annexe figure 1 : pipeline de l'entraînement et optimisation d'un modèle de reconstruction semi-supervisée
(référence : Maria Herrero-Tudela et al., 2025 [25])



annexe figure 2 : pipeline de l'entraînement et optimisation d'un modèle de classification supervisé
(référence : Maria Herrero-Tudela et al., 2025 [25])

```
// C.L 20160630 AB_Group R337 30166-(1) PHLB:mis à jour cas R337 avec detection et ejection
// -----
( NOT ( bDdeDeceVLGenPHLB ) OR NOT ( bTemSelPHLBProd ) OR NOT ( PIHM_SPU.bConf_PHLBO
( NOT ( bForcEjecSacDefLectSacPHLB ) OR NOT ( bTemSelPHLBProd ) OR NOT ( bTemSelDetSacPHLBPro
// -----
( NOT ( bDdeDeceVLBoyOuvMach ) OR NOT ( PIHM_SPU.bConf_CelBoyOuv ) ) AND // C.L 201
( NOT ( bActDecelAutoVLMangCol ) OR NOT ( PIHM_SPU.bConf_DefManqueColle ) ) OR // HOL 201
( VIHM_bDiagnosticIA AND rConscad <= 29.95 ) AND // Projet GIO IA 2025 METTLER 30561 -
1 THEN
```

annexe figure 3 : modification du FC_Gen (programme ST) pour accélérer ou décélérer la machine à la cadence voulue, ici 30 sac / mins avec delta = 0.05 pour intervalle d'acceptation



annexe figure 4.a : création d'un bouton pour aller dans la page de diagnostic, sur la RS26
Mettler, 30561 à Holweg, Molsheim



annexe figure 4.b : page d'accueil avec plusieurs sections. La machine ne tourne pas encore.

(a) : Page de diagnostic : permet de lancer un diagnostic, suivre son déroulement et afficher le résultat de l'IA

(b) : Page d'entraînement : pour réentraîner notre modèle si il n'y en a pas ou si il y a en besoin. Pour éviter de modifier les poids du modèle, cette page sera réservée aux automaticiens.

(c) : **Bouton RUN** : lance un premier code pour forcer la machine à la cadence voulue. Il ne fonctionne que si la machine est en **marche machine**.

(d) : **Bouton MANUEL RESET** : permet de stopper le diagnostic et réinitialiser le diagnostic de l'IA en cas de problèmes.

(e) : **Table d'affichage** : affiche la date du diagnostic, ainsi que l'ID du label, la signification en texte ainsi que l'indice de certitude du diagnostic en %.


Remarques : L'ID du label sera défini dans *nodeRed* afin de faciliter le *debug* en cas de mauvais diagnostic. "ID 99" signifie qu'aucun label n'a été trouvé.



annexe figure 4.c : démonstration du suivi du processus via la page de diagnostic, en mode RUN (a). Lorsqu'un processus est achevé, la LED grise (b) devient verte (c).



annexe figure 4.c : réponse de l'IA après un diagnostic, effectué 20 minutes plus tôt. label "ID 0" signifie pas d'anomalie avec 100% de certitude.



annexe figure 4.d : page d'entraînement uniquement accessible par les automaticiens, avec la liste des labels disponibles

Cette interface permet l'entraînement de l'IA. Le but est de premièrement assigner un label (a) et ensuite faire tourner la machine à la cadence spécifique (b) pour stocker la table dans le boîtier Belden. Une fois toutes les données récoltées, le bouton LEARN doit être appuyé pour lancer l'entraînement (c).

Remarques : Cette partie n'a pas pu être raffinée dû à un manque de temps. Néanmoins, l'intérêt de la page (b) est de pouvoir répliquer diverses anomalies sur l'axe en question.

Exemple : Axe Arrache (Axe Arra) → Position → "--"

→ signification : sur l'axe d'arrache, décaler la position d'arrache pour qu'il soit trop tard par rapport au maintien.





figure 4.e : page de confirmation pour réentraîner le modèle


Remarques : Il est totalement possible d’entraîner l’IA uniquement sur quelques labels uniquement. Aucune restriction n’est mise en place à ce sujet.
La zone (d) est réservée pour créer une table de supervision de l’entraînement. De cette façon, l’utilisateur peut suivre les étapes de l’entraînement et savoir si un problème est apparu.

Exemple : l’entraînement n’a pas convergé, manque de données, manque de labels, sauvegarde impossible, connexion au boîtier Belden impossible, dysfonctionnement de la machine, cadence instable etc...



annexe figure 5 : configuration du webservice *Simotion* afin d’exporter les variables de l’automate en question - RS26 Mettler 30561 à Holweg, Molsheim

Remarques : Pour configurer l'automate, nous devons tout d'abord mettre la sécurité en LOW, créer les bons utilisateurs (admin, holweg, DataCollectors) et ensuite sélectionner le bon port ainsi que les autorisations.



annexe figure 6 : vérification des variables à travers la *watch table* de simotion webserver - RS26 Mettler 30561 à Holweg, Molsheim

La *watch table* du *Simotion* nous permet de visualiser les valeurs de variables en cas de problème. Cette fonction est utile lors de debug.




figure 6.a : vue d'ensemble de l'interface *nodeRED* mise en place pour traiter, communiquer et envoyer les données de l'automate au Belden et à l'IA

Pour faciliter la lecture des nœuds, des *Link IN* et *Link OUT* ont été mis en place. Les figures ci-dessous sont affichées pour mettre en valeur quel *Link* sont connectés ensemble.




figure 6.b : Links pour lire les données OPC UA




figure 6.c : Links pour écrire les données OPC UA




figure 6.d : Link intermédiaire pour faciliter et aérer les noeuds




figure 6.e : zoom sur chaque composants mise en place sur la figure 6.a

- (a) : Regarde constamment si un bouton a été appuyé
- (b) : Si la collecte des données a été achevé, alors demander à lire tous les tableaux à l'OPC UA Server et envoyer une mise à jour sur l'IHM
- (c) : Si la demande est acceptée, alors lire tous les tableaux, les joindre dans un tableau unique. De plus, sauvegarder les données en fichier .h5 et l'envoyer dans le bloc diagnostic
- (d) : Reçoit les données et les envoie dans le Rest Flask API de notre conteneur IA-diagnostic pour un diagnostic. Écrit le diagnostic ainsi qu'une mise à jour à l'IHM
- (e) : Sauvegarder les données .h5 dans un volume de notre conteneur en local.


(f) : Fonction pour écrire les données vers l'OPC UA Server

(g) : A l'appui d'un bouton IHM, supprimer tous les fichiers .h5 contenu dans le volume de notre conteneur


(h) : Si le bouton TRAIN est appuyé, alors lancer une requête au Rest Flask API de notre conteneur IA-training pour entraîner notre IA à partir des fichiers .h5 disponible dans le volume de notre conteneur.

Envoie aussi une mise à jour à l'IHM en cas d'erreur.

Remarques : Il est important de noter que rajouter plus de blocs OPC UA va crasher le *nodeRED* du belden. C'est pourquoi, nous n'avons que ces deux blocs disponibles : l'un est pour lire, l'autre est pour écrire.



annexe figure 8 : vérification que les données extraites ont la bonne dimension et les bonnes valeurs



annexe figure 9 : exemple de multiple conteneur tournant de manière synchronisé à partir de la même image.

Chaque conteneur contient son propre script, son propre point d'accès et ses propres librairies

(source : Fabio D'Urso et al., 2019 [23])

Below are the reserved ports for system services:

Ports	Service
53, 67	dnsmasq
68	dhclient
123	ntpd
8085	Edge.service
124	modbusagent

Page 75 of 128

OpEdge
Industrial Edge Gateway – Release 01.1.00 – 01/2025

2222	sshd
50000	discovery
8080	go-igp webserver
21,22	file relay
443	tunnelling
161	SNMP

annexe figure 10 : les ports à ne pas utiliser d’après le manuel Hirschmann OpEdge 8D

Applications

+ Add

Containers

Virtual Machines

Images

Storage

Networks


FILTER: Show All

Search


Status	Name	Date Created	Port Mapping @	Volumes @	CPU %	RAM Usage/Limit	Main Action	Other
Running	hwg_al_diagnostic_1_4_1	May 27 2025 07:11:08	4040:4040	hwg_1_4_1_m0...	0.0	134.1 MB / 1024.0 MB	■	...
Running	hwg_al_trainer_1_4_1	May 27 2025 07:03:02	5050:5050	hwg_1_4_1_m0...	0.0	173.5 MB / 1024.0 MB	■	...
Running	hwg_al_saver_1_4_1	May 27 2025 06:59:48	6060:6060	hwg_1_4_1_m0...	0.0	33.7 MB / 1024.0 MB	■	...
Running	bhdo_3_16_4_new	Mar 20 2025 09:42:48	443:8443	bhdo_3_16_4_n...	147.5	815.7 MB / 4096.0 MB	■	...
Stopped	bhdo_3_16_4	Feb 27 2025 10:35:17					▶	...
Stopped	belden_std_docker	Jun 28 2025 15:54:02					▶	...

Module rajouté

annexe figure 11 : les trois conteneurs sont en routes avec les ports HTTP exposés correctement - Belden OpEDGE 8D (BHDO)



annexe figure 12 : installation d'un IO-Link MASTER Ethernet en prototype pour tester et valider l'utilisation du capteur de vibration - Pepperl & Fuchs



annexe figure 13 : détail sur les types et dimension des couches utilisés dans le VAE

annexe définition 1 : Un fichier .h5 est un conteneur de données utilisant le format HDF5 (Hierarchical Data Format version 5), conçu pour stocker et organiser efficacement de très grands volumes de données structurées. Il est similaire au format (.csv).

annexe définition 2 : Un volume Docker est une zone de stockage gérée par Docker, indépendante du cycle de vie des conteneurs, qui permet de :

- Persister des données : les volumes conservent leurs contenus même si le conteneur est supprimé.
- Partager des données : plusieurs conteneurs peuvent monter le même volume en lecture/écriture.
- Isoler les dépendances : séparer les données (logs, bases, fichiers générés) de l'image et du système de fichiers du conteneur.

source : Docker Docs – Volumes

annexe définition 3 : La distance Mahalanobis est une métrique de distance entre un point P et une probabilité de distribution D , introduite par Mahalanobis en 1936. Elle permet ainsi de calculer la distance d'un point de test du centre de masse d'un cluster.

$$\begin{aligned}\Pr[\vec{x}] d\vec{x} &= \frac{1}{\sqrt{\det(2\pi\Sigma)}} \exp\left(-\frac{(\vec{x} - \vec{\mu})^\top \Sigma^{-1} (\vec{x} - \vec{\mu})}{2}\right) d\vec{x} \\ &= \frac{1}{\sqrt{\det(2\pi\Sigma)}} \exp\left(-\frac{d^2}{2}\right) d\vec{x}.\end{aligned}$$


Dans notre cas, calculer cette distance est plus intrigant que d'autres comme la distance *cosine* car notre jeu de données présente déjà une distribution probabiliste gaussienne, issue de l'espace latent de notre VAE (**figure 25**).

annexe définition 4 : Le VGG16 est un modèle utilisé dans un concours de prédiction d'image basé sur un dataset *ImageNet* (Karen Simonyan & Andrew Zisserman, 2015 [27]). Ce modèle complexe est largement reconnu pour sa simplicité et sa capacité à reconnaître des motifs très profonds au sein des images.

Aujourd'hui, il est largement utilisé pour le *transfer learning* dans le cadre d'études dans des domaines d'images spécialisées, comme la détection de cancer.

annexe définition 5 : Un embedding est une fonction f qui mappe des objets discrets (mots, images, suites de donnée longue) vers un espace vectoriel de dimension d plus petit, de sorte que des objets ayant des similitudes aient des représentations proches dans cet espace.

Typiquement, la sortie de l'embedding est ensuite utilisée soit pour visualiser plusieurs groupes à travers des algorithmes de réduction de dimensionnalité comme le t-SNE (**annexe définition 6**), soit pour être classifié directement.



exemple concret du rôle d'un embedding
(source page internet : What are Vector Embeddings?)

annexe définition 6 : L'algorithme t-SNE est un algorithme de réduction de dimensionnalité non-linéaire utilisé pour aider à la visualisation de données à haute dimension (>3).

Il est énormément utilisé chez les scientifiques pour prouver que le modèle ou les données utilisées présente des groupes distincts pour la classification.




figure 20 : représentation à partir du t-SNE de l'espace latent sur le MNIST dataset
(source : Asif Ahmed Neloy & Maxime Turgeon, 2024 [17])

annexe définition 7 : Le KNN est un algorithme de *machine learning* ne nécessitant pas d'entraînement et ne contenant pas de neurones. C'est un modèle utilisé pour classifier des jeux de données à travers une comparaison de distance suivant les centroïdes de clusters (expliqué dans le **chap IV. 2**).

annexe définition 8 : La perplexity (ou perplexité en français) est un paramètre de l'algorithme t-SNE définissant la profondeur du calcul nécessaire pour qu'un point soit proche d'un autre. Autrement dit, si la perplexité est trop élevée, alors tous les points seront éloignés à équidistance de l'un de l'autre. Au contraire, si la perplexité est trop basse, alors tous les points seront proches, créant ainsi un cluster unique difficile à séparer visuellement.

annexe définition 9 : Le CNN ou couche convolutive est un bloc de base dans un réseau de neurones conçu pour traiter des données de dimension supérieur à un, comme un tableau, image, vidéo ou autre.

Sa particularité réside dans sa façon de réagir aux données : au lieu d'apprendre à chaque pixel, comme une couche linéaire ou dense, la couche CNN apprend à reconnaître des motifs spatiaux (par exemple un bord, un motif, une texture), ce qui le rend plus efficace pour traiter des images ou des signaux à deux dimensions.

annexe définition 10 : La précision (ou accuracy en anglais) est une métrique visant à montrer la performance d'un modèle. Le calcul de cette métrique est illustré dans la **figure A, ci-dessous**. La base repose donc sur le calcul de la prédiction où chaque valeur diagonale représente une bonne prédiction. Ainsi, dans le cas où le modèle est parfait, la précision serait de 100%, soit une diagonale parfaite.




figure A : calcul de la précision à partir d'une matrice de confusion
(exemple pris de : Sebastian Bittrich et al., 2019 [28])

PR : precision - proportion d'observations prédites positives qui sont effectivement positives

RE : recall - proportion d'observations positives correctement identifiées

F1 : score F1 - moyenne harmonique entre la précision et le rappel

CA : accuracy - proportion totale d'observation correctement placée

Remarque : Dans la majeure partie des cas, l'accuracy (précision) est la métrique significative.

Université de Strasbourg
Faculté de Physique et Ingénierie

**MASTER PAIP parcours Mécatronique, Énergie et Systèmes
Intelligents (MESI)**

Auteur : SO Gio

Titre : Conception d'une Intelligence Artificielle afin d'assister les régulateurs et d'éviter les casses-papier durant la formation du boyau

Structure d'accueil : HolwegWeber Group

Département / pays : Alsace, France

Résumé : Dans le cadre du master Mécatronique, Énergie et Systèmes Intelligents (MESI), nous avons réalisé un projet de fin d'étude, visant à développer et implémenter un modèle d'IA capable d'optimiser une machine industrielle, réduire la casse-papier et assister les régulateurs. À partir de différents signaux récoltés, comme la vibration, le son ou le couple moteur, une étude a été menée afin de prouver l'intérêt de l'utilisation de l'IA dans notre situation. Le travail s'articule ainsi autour de l'emplacement et la sélection des capteurs, du traitement de signal et du développement de modèles basés sur des réseaux de neurones. Diverses approches comme des autoencodeurs variationnel multivue (VAE-MV) ainsi que des classificateurs à base de CNN ont été exploités. Les résultats montrent une précision supérieure à 80 %, en utilisant des images scalogrammes pour la vibration ainsi que melspectrogrammes pour le son.

Le temps et la disponibilité des machines ont limité le déploiement à la phase finale de tests. Néanmoins, cette preuve de concept offre déjà à l'entreprise un socle solide pour poursuivre vers une solution industrielle complète, alignée avec les objectifs de l'industrie 5.0.

Mots clés : optimisation de machines, optimisation de processus, détection d'anomalie, maintenance prédictive, intelligence artificielle, industrie 4.0, industrie 5.0, automatisme, deep machine learning, vibration, acoustique, siemens

Abstract : As part of the Mechatronics, Energy, and Intelligent Systems master's program (MESI), we completed a final-year project aimed at developing and implementing an AI model capable of optimizing an industrial machine, reducing paper tear, and assisting operators. Based on various signals collected, such as vibration, sound, and motor torque, we conducted a study to demonstrate the value of AI in our context. Our work focused on sensor placement and selection, signal processing, and the development of neural network-based models. We explored several approaches, including multiview variational autoencoders (VAE-MV) and CNN-based classifiers. Using scalogram images for vibration and mel-spectrograms for sound, our models achieved over 80 % robustness and accuracy.

Machine availability and time constraints limited the deployment to the final phase of tests. Nonetheless, this proof of concept already provides the company a solid foundation on which to build a full industrial solution aligned with the 5.0 industry objectives.

Keywords : machine optimization, process optimization, anomaly detection, predictive maintenance, artificial intelligence, 4.0 industry, 5.0 industry, automatism, deep machine learning, vibration, acoustic, siemens